

直接的な選好最適化: あなたの言語モデルは実は報酬モデルです

ラファエル・ラファイロフ †

アーキット・シャルマ †

エリック・ミッチェル †

ステファノ・エルモン† ‡

クリストファー・D・マニング†

チェルシー・フィン†

†スタンフォード大学 ‡ CZ Biohub

{rafailov,architsh,eric.mitchell}@cs.stanford.edu

抽象的な

大規模な教師なし言語モデル (LM) は、幅広い世界知識とある程度の推論スキルを学習しますが、トレーニングが完全に教師なしであるため、その動作を正確に制御することは困難です。このような操縦性を獲得するための既存の方法は、モデル生成の相対的な品質の人間によるラベルを収集し、多くの場合、人間からのフィードバックからの強化学習 (RLHF) を使用して、これらの好みに合うように教師なし LM を微調整します。しかし、RLHF は複雑で不安定な手順であり、最初に人間の好みを反映する報酬モデルを適合させ、次に強化学習を使用して大規模な教師なし LM を微調整し、元のモデルから大きくずれることなくこの推定報酬を最大化します。本稿では、対応する最適ポリシーを閉じた形式で抽出できるようにする RLHF の報酬モデルの新しいパラメータ化を紹介し、単純な分類損失のみで標準的な RLHF 問題を解決できるようにします。得られたアルゴリズム (直接選好最適化 (DPO) と呼ぶ) は、安定性、パフォーマンス、そして計算量ともに軽量であり、微調整や大幅なハイパーパラメータ調整の際に言語モデルからサンプリングを行う必要がありません。実験では、DPO は既存の手法と同等かそれ以上に、人間の選好に合わせて言語モデルを微調整できることが示されています。

特に、DPO による微調整は、世代の感情を制御する能力において PPO ベースの RLHF を上回り、要約と単一ターンの対話における応答品質に匹敵または向上する一方で、実装とトレーニングが大幅に簡単になります。

1 はじめに

非常に大規模なデータセットで学習させた大規模な教師なし言語モデル (LM) は、驚くべき能力を獲得する [11, 7, 42, 8]。しかし、これらのモデルは、さまざまな目標、優先順位、スキルセットを持つ人間によって生成されたデータで学習されている。これらの目標やスキルセットの一部は、模倣することが望ましくないかもしれない。たとえば、AI コーディングアシスタントに一般的なプログラミングミスを理解して修正させたい一方で、コード生成時には、トレーニングデータ内に存在する (稀ではあるが) 高品質なコーディング能力にモデルを偏らせたい場合がある。同様に、言語モデルに、50% の人が信じている一般的な誤解を認識させたいが、その言語モデルに関するクエリの 50% でこの誤解が正しいと主張するようなことは絶対に避けたい。

言い換えれば、モデルの広範な知識と能力から望ましい応答と行動を選択することは、安全で高性能かつ制御可能な AI システムを構築する上で極めて重要である [28]。既存の手法では、強化学習 (RL) を用いて学習モデルを人間の好みに合わせて誘導するのが一般的であるが、

貢献度は同等。より若い著者が先にリストされています。




図1: DPOは強化学習を回避しながら人間の嗜好を最適化します。人間のフィードバックを用いて言語モデルを微調整する既存の手法では、まずプロンプトと人間の嗜好のデータセットに報酬モデルを適合させ、その後、強化学習を用いて学習した報酬を最大化する方策を見つけます。対照的に、DPOは、対応する最適なポリシーを閉じた形式で抽出できる暗黙の報酬モデルを適合させ、単純な分類目標で好みを最もよく満たすポリシーを直接最適化します。

既存の方法で使用されている RL ベースの目的が、単純なバイナリクロスエントロピー目的によって正確に最適化され、選択学習パイプラインが大幅に簡素化されることを示します。

大まかに言えば、既存の手法では、人間が安全かつ有用であると考えられる行動の種類を表す厳選された人間の嗜好セットを用いて、望ましい行動を言語モデルに植え付けます。この嗜好学習段階は、大規模なテキスト データセットを用いた大規模な教師なし事前学習の初期段階の後に行われます。嗜好学習への最も直接的なアプローチは、人間による高品質な応答のデモンストレーションに基づく教師あり微調整ですが、最も成功している手法のクラスは、人間（または AI）からのフィードバックによる強化学習 (RLHF/RLAIF; [12, 2]) です。RLHF 手法は、報酬モデルを人間の嗜好のデータセットに適合させ、強化学習を使用して言語モデルポリシーを最適化し、元のモデルから大きく逸脱することなく、高い報酬が割り当てられた応答を生成します。RLHF は優れた会話能力とコーディング能力を持つモデルを生成しますが、RLHF パイプラインは教師あり学習よりもかなり複雑で、複数の LM をトレーニングし、トレーニンググループで LM ポリシーからサンプリングする必要があり、かなりの計算コストがかかります。

本稿では、明示的な報酬モデリングや強化学習なしに、言語モデルを直接最適化して人間の嗜好に合わせる方法を示す。我々は、既存のRLHFアルゴリズム (KLダイバージェンス制約による報酬最大化)と同じ目的を暗黙的に最適化するアルゴリズムである直接選択最適化 (DPO)を提案するが、実装が簡単でトレーニングも簡単である。直感的には、DPOの更新は好まれる応答と好まれない応答の相対的な対数確率を増加させるが、動的な例ごとの重要度の重みを組み込んでおり、単純な確率比目的で発生することがわかったモデルの退化を防ぐ。既存のアルゴリズムと同様に、DPOは、与えられた報酬関数が経験的な選択データとの程度一致しているかを測定する理論的な選択モデル (Bradley-Terryモデルなど、[5])に依存している。しかし、既存の手法では、選択モデルを用いて選択損失を定義し、報酬モデルを学習した後、学習済みの報酬モデルを最適化する方策を学習するのに対し、DPOでは変数の変更を用いて、選択損失を方策の関数として直接定義します。したがって、モデルへの応答に対する人間の選択に関するデータセットが与えられた場合、DPOは単純な2値交差エントロピー目的関数を用いて方策を最適化し、選択データに適合した暗黙的な報酬関数に最適な方策を生成することができます。

私たちの主な貢献は、選択に基づいて言語モデルを学習する、強化学習を必要とせずシンプルなアルゴリズムである直接選択最適化 (DPO)です。実験の結果、DPOは、感情変調、要約、対話といったタスクにおいて、最大60億個のパラメータを持つ言語モデルを用いて、選択から学習する上で、PPOベースのRLHFを含む既存の手法と同等以上の効果があることが示されました。

2 関連研究

規模の拡大する自己教師あり言語モデルは、いくつかのタスクをゼロショット[33]または数ショットのプロンプト[6, 27, 11]で完了することを学習します。しかし、下流タスクでのパフォーマンスとユーザーの意図との整合性は、指示と人間が書いた補完のデータセットを微調整することで大幅に改善できます[25, 38, 13, 41]。この「指示チューニング」手順により、LLM は指示チューニングセット外の指示に一般化でき、一般的に使いやすさが向上します[13]。指示チューニングの成功にもかかわらず、応答の品質に関する相対的な人間の判断は、専門家のデモンストレーションよりも収集が容易な場合が多く、そのため、その後の研究では、人間の好みのデータセットを使用して LLM を微調整し、翻訳[20]、要約[40, 51]、ストーリーテリング[51]、および指示に従う[28, 34]の熟練度を向上させました。これらの方法は、まず、ニューラルネットワークの報酬関数を、以下のような選択モデルにおける選択データセットとの互換性のために最適化する。

ブラッドリー・テリーモデル[5]を用いて言語モデルを微調整し、与えられた報酬を最大化します。強化学習アルゴリズムとしては、一般的には REINFORCE [47]、近似方策最適化(PPO; [39])、またはその派生[34] が用いられます。これと密接に関連する研究としては、人間のフィードバックを伴う指示に微調整された LLM を活用して、安全性や無害性などの対象属性に対する追加の合成選好データを生成するものがあります [2]。このとき、LLM の注釈にはテキストによるルーブリックという形で人間からの弱い監督のみを用います。これらの手法は、2 つの研究領域の融合を表しています。1 つは、さまざまな目的で強化学習を用いて言語モデルをトレーニングする研究領域[35, 29, 48]であり、もう 1 つは人間の選好から学習する一般的な手法に関する研究領域[12, 21] です。人間の相対的な選好を用いることは魅力的ですが、大規模な言語モデルを強化学習で微調整することは、依然として大きな実際の課題です。本研究は、強化学習なしで相対的な選好を最適化するための、理論的に正当化されたアプローチを提供します。

言語の文脈以外では、嗜好からのポリシーの学習は、バンディット学習と強化学習の両方の設定で研究されており、いくつかのアプローチが提案されている。報酬ではなく、行動の嗜好やランキングを使用するコンテキストバンディット学習は、コンテキストデュエルバンディット (CDB; [50, 14])として知られている。絶対報酬がない場合、CDBの理論的分析では、最適ポリシーの概念をフォンノイマン勝者、つまり他のポリシーに対する期待勝率が少なくとも50%であるポリシーに置き換えている[14]。ただし、CDB設定では、嗜好ラベルはオンラインで付与されるのに対し、人間の嗜好から学習する場合、通常、オフラインの嗜好が注釈付けされた行動ベアの固定バッチから学習する[49]。同様に、嗜好ベースRL (PbRL)は、報酬ではなく、未知の「スコアリング」関数によって生成されたバイナリ嗜好から学習する[9, 37]。PbRLには様々なアルゴリズムが存在し、その中には政策外選好データを再利用できる手法も含まれていますが、一般的にはまず潜在スコアリング関数 (すなわち報酬モデル)を明示的に推定し、その後それを最適化する必要があります[16, 9, 12, 36, 21]。本研究では、選好を満たすように政策を直接最適化する、単一段階の政策学習アプローチを提示します。

3 予備

Zieglerら (および後続[40, 1, 28])のRLHFパイプラインをレビューする。このパイプラインは通常、 1) 教師あり微調整 (SFT) 2) 選好サンプリングと報酬学習、3) RL最適化の3つのフェーズから構成される。

SFT: RLHFは通常、対象となる下流タスク (対話、要約など)の高品質データに対する教師あり学習で事前学習済みのLMを微調整することから始まり、モデル π を取得します。

報酬モデリングフェーズ 第2フェーズでは、SFTモデルにプロンプト x が提示され、回答のベア (y_1, y_2) π SFT($y | x$)が生成される。これらの回答は、人間のラベル付け担当者に提示され、ラベル付け担当者は、 $y_w, y_l | x$ と表記される1つの回答に対する選好を表す。ここで、 y_w と y_l は、それぞれ (y_1, y_2) の中で好ましい補完と好ましくない補完を表す。選好は、潜在報酬モデル $r(x, y)$ によって生成されると仮定されるが、このモデルにはアクセスできない。選好をモデル化する手法はいくつかあるが、Bradley-Terry (BT) [5]モデルが広く採用されている (ただし、より一般的なPlackett-Luceランキングモデル[32, 23]も、複数のランク付けされた回答にアクセスできる場合は、このフレームワークと互換性がある)。BTモデルは、人間の選好分布 p が

次のように書くことができます。

$$p(y_2 | x) = \frac{\exp(r(x, y_1))}{\exp(r(x, y_1)) + \exp(r(x, y_2))} \tag{1}$$

比較の静的データセット $D = \{x, y_w, y_l\}$ にアクセスできると仮定すると、報酬モデル $r(x, y)$ をパラメータ化し、最大尤度を使用してパラメータを推定でき、 p からサンプリング、私たちが

きます。

問題をバイナリ分類として捉えると、負の対数尤度損失が得られます。

$$LR(r, D) = -E(x, y_w, y_l) \log \sigma(r(x, y_w) - r(x, y_l)) \tag{2}$$

スティック関数である。LMの文脈では、ネットワーク $r(x, y)$ は多くの場合、SFTモデル π SFT($y | x$)から初期化され、最終のトランスフォーマー層の上に報酬値の単一のスカラー予測を生成する線形層が追加される[51]。より低い分散の報酬関数を確保するために、以前の研究では、すべての x に対して $E_x, y \in D [r(x, y)] = 0$ となるように報酬を正規化している。

強化学習の微調整段階 強化学習段階では、学習した報酬関数を用いて言語モデルにフィードバックを与える。先行研究[17, 18]に従い、最適化は以下のように定式化される。

$$\max_{\pi} E_{x \in D, y \sim \pi} \theta(y|x) r(x, y) - \beta DKL(\pi \theta(y|x) || \pi_{ref}(y|x)), \tag{3}$$

ここで、 β は基本参照ポリシー π_{ref} 、つまり初期SFTモデル π_{SFT} からの偏差を制御するパラメータである。実際には、言語モデルポリシー π_θ も π_{SFT} に初期化される。追加された制約は、モデルが報酬モデルが正確である分布から大きく逸脱するのを防ぎ、生成の多様性を維持し、単一の高報酬の答えへのモード崩壊を防ぐため重要である。言語生成の離散的性質のため、この目的は微分可能ではなく、通常は強化学習で最適化される。標準的なアプローチ[51, 40, 1, 28]は、報酬関数 $r(x, y) = r(x, y) - \beta(\log \pi_\theta(y|x) - \log \pi_{\text{ref}}(y|x))$ を構築し、PPO [39]を使用して最大化することである。

4 直接的な選好最適化

強化学習アルゴリズムを、言語モデルの微調整などの大規模な問題に適用する際の課題に動機づけられ、私たちの目標は、好みを直接使用するポリシー最適化のための単純なアプローチを導き出すことです。報酬を学習してから強化学習を介して最適化する従来のRLHF法とは異なり、私たちのアプローチは、RLトレーニンググループなしで閉じた形式で最適なポリシーを抽出できるようにする報酬モデルのパラメータ化の特定の選択を活用します。次に詳しく説明するように、私たちの重要な洞察は、報酬関数から最適なポリシーへの解析的マッピングを活用することです。これにより、報酬関数上の損失関数をポリシー上の損失関数に変換できます。この変数変更アプローチは、明示的なスタンドアロンの報酬モデルの適合を回避しながら、Bradley-Terryモデルなどの既存の人間の好みのモデルの下で最適化を続けます。

本質的には、ポリシー ネットワークは言語モデルと (暗黙の) 報酬の両方を表します。

DPO目的関数の導出。一般的な報酬関数 r のもとで、先行研究と同じ強化学習目的関数 (式3)から始める。先行研究[31, 30, 19, 15]に従えば、式3のKL制約付き報酬最大化目的関数の最適解が以下の形になることは明らかである。

$$\pi(r|y|x) = \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{Z(x)} r(x, y), \beta \right) \quad (4)$$

ここで、 $Z(x) = \sum_y \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{r(x, y)} \right)$ は完全な導出。ここで、 $\frac{1}{r(x, y)}$ は分配関数である。 β については付録A.1を参照のこと。

出である。真の報酬関数 r のMLE推定値 \hat{r} を用いたとしても、分配関数 $Z(x)$ の推定には依然としてコストがかかるため[19, 15]、この表現を実際に利用することは難しい。しかし、式4を変形することで、報酬関数を対応する最適方策 π 、参照方策 π_{ref} 、および未知の分配関数 $Z(\cdot)$ で表すことができる。

具体的には、まず式4の両辺の対数を取り、代数演算によって次式を得ます。

$$r(x, y) = \beta \log \frac{\pi(r|y|x)}{\pi_{\text{ref}}(y|x)} \quad (5)$$

この再パラメータ化をグラウンドトゥールズ報酬 r に適用することができる。および対応する最適モデル。幸いなことに、 π Bradley-Terryモデルは2つの完了間の報酬の差、すなわち $p(y_1, y_2|x) = \sigma(r(x, y_1) - r(x, y_2))$ のみに依存します。式5の $r(x, y)$ の再パラメータ化を選好モデル式1に代入すると、分配関数がキャンセルされ、Bradley-Terryモデルの参照ポリシーは選好モデルを満たすことがわかります。人間の選好確率は、最適政策 π と π_{ref} のみで表現される。したがって、最適RLHF政策 π

$$p(y_1, y_2|x) = \frac{\pi(y_1|x) \pi(y_2|x)}{\pi(y_1|x) \pi(y_2|x) + \pi(y_2|x) \pi(y_1|x)} \quad (6)$$

導出は付録A.2に示されています。式6はBradley-Terryモデルを用いていますが、より一般的なPlackett-Luceモデル[32, 23]でも同様に式を導出することができ、付録A.3に示されています。

報酬モデルではなく最適なポリシーの観点から人間の好みのデータの確率が得られたので、パラメーター化されたポリシー π_θ の最大尤度目的を定式化できます。報酬モデリングアプローチ (すなわち式2)と同様に、私たちの政策目標は次のようになります。

$$\text{LDPO}(\pi_\theta; \pi_{\text{ref}}) = -\mathbb{E}(x, y_w, y_l) \left[\log \sigma \beta \log - \beta \log \frac{\pi_\theta(y_w|x) \pi_\theta(y_l|x)}{\pi_{\text{ref}}(y_w|x) \pi_{\text{ref}}(y_l|x)} \right] \quad (7)$$

このようにして、代替パラメータ化を用いて暗黙の報酬を適合させる。その最適方策は単に π_θ である。さらに、この手順は再パラメータ化されたBradley-Terry法を適合させることと同等であるため、

モデルは、選好データ分布の適切な仮定の下での一貫性など、一定の理論的性質を備えている[4]。第5節では、DPOの理論的性質を他の研究と関連付けてさらに議論する。

DPO更新はどのような働きをするのでしょうか？ DPOのメカニズムを理解するには、損失関数LDPOの勾配を分析することが有用です。パラメータθに関する勾配は次のように表されます。

$$\nabla_{\theta} \text{LDPO}(\pi_{\theta}; \pi_{\text{ref}}) = -\beta \mathbb{E}_{(x, y_w, y_l) \sim D} \left[\frac{\sigma(r_{\theta}(x, y_l) - r_{\theta}(x, y_w))}{\pi_{\theta}(y_l | x) - \pi_{\theta}(y_w | x)} \nabla_{\theta} \log \pi(y_w | x) - \nabla_{\theta} \log \pi(y_l | x) \right]$$

報酬の推定が間違っている場合は重みが増す ywの可能性を高める ylの可能性を減らす

ここで、 $r_{\theta}(x, y) = \beta \log \pi_{\theta}(y | x)$ は、言語モデル π_{θ} の報酬によって暗黙的に定義される報酬です(詳細はセクション 5 を参照)。直感的には、損失関数 LDPO によって、好ましい完了 y_w の尤度が上がり、好ましくない完了 y_l の尤度が下がります。重要なのは、暗黙の報酬モデル r_{θ} が好ましくない完了をどれだけ高く評価するかによって例が重み付けされ、 β でスケールされることです。つまり、暗黙の報酬モデルが完了をどれだけ間違っ順序付けしているかによって重み付けされ、KL 制約の強さが考慮されています。私たちの実験では、この方法の重み係数のない単純なバージョンでは言語モデルが退化する可能性があるため、この重み付けの重要性が示唆されています(付録表 3)。

DPO の概要。一般的な DPO パイプラインは次のとおりです。1) すべてのプロンプト x について補完 $y_1, y_2 \sim \pi_{\text{ref}}(\cdot | x)$ をサンプリングし、人間の好みでラベルを付けて、オフラインの好みのデータセット $D = \{(x, y_w), (x, y_l)\}$ を構築し、2) 言語モデル π_{θ} を最適化して、指定された π_{ref} と D および望ましい β に対して LDPO を最小化します。実際には、サンプルを生成して人間の好みを収集するのではなく、公開されている好みのデータセットを再利用することが望まれます。好みのデータセットは π SFT を使用してサンプリングされるため、 $\pi_{\text{ref}} = \pi$ が利用できない場合は、好ましい補完 (x, y_w) の尤度を最大化するように π_{ref} を初期化します。つまり、 $\pi_{\text{ref}} = \arg \max_{\pi} \mathbb{E}_{(x, y_w) \sim D} [\log \pi(y_w | x)]$ です。この手順は、利用できない真の参照分布と DPO で使用される π_{ref} との間の分布のシフトを軽減するのに役立ちます。実装とハイパーパラメータに関する詳細は、付録 B に記載されています。

5 DPOの理論的分析

このセクションでは、DPO法のさらなる解釈と理論的裏付けを示し、DPOの利点とRLHFに使用されるアクタークリティックアルゴリズム (PPO [39]など)の問題を関連付けます。

5.1 言語モデルは実は報酬モデルである

DPOは、明示的な報酬のフィッティングと強化学習の実行を回避し、単一の最大尤度目的関数を用いて方策を学習することができます。最適化目的関数 J は、 $(y|x)$ と等価であることに留意してください。

する Bradley-Terry モデル $(x, y) = \beta \log$ を用いて、 $\pi_{\text{ref}}(y|x)$ / パラメトリックモデル π_{θ} の最適化を最小化する有、変数 θ の下での式2の報酬モデル最適化と本節では、この再パラメータ化の背後にある理論を構築し、学習済み報酬モデルのクラスを制約しないこと、そして最適な方策を正確に復元できることを示します。まず、報酬関数間の同値関係を定義します。

定義1. 2つの報酬関数 $r(x, y)$ と $r'(x, y) = r + f$ があるとする。 $f(x, y)$ は、ある関数 f に対して $(x, y) = f(x)$ となる。

これは確かに同値関係であり、報酬関数の集合をクラスに分割するものであることは容易に理解できる。以下の2つの補題を述べる事ができる。補題1 :ブラケット＝ルース、特にブラッドリー＝テリーの選好枠組みにおいては、同じクラスに属する2つの報酬関数は同じ選好分布を誘導する。

補題 2.同じ同値類からの 2 つの報酬関数は、制約付き RL 問題の下で同じ最適ポリシーを誘導します。

証明は簡単なので付録A.5に譲る。最初の補題は、ブラケット・ルースモデル族[32]におけるよく知られた仕様不足問題である。この仕様不足のため、

通常、式 2 の MLE 推定値に何らかの保証を与えるためには、追加の識別可能性制約を課す必要がある[4]。2 番目の補題は、同じクラスのすべての報酬関数は同じ最適ポリシーを生成すること述べているため、最終目的では、最適クラスから任意の報酬関数を復元することのみに関心がある。付録 A.6 で次の定理を証明します。定理 1. 弱い仮定の下では、Plackett-Luce (および特に Bradley-Terry) モデルと整合するすべての報酬クラスは、あるモデル $\pi(y | x)$ と与えられた参照モデル $\pi_{\text{ref}}(y | x)$ に対して、再パラメータ化 $\pi(y|x) r(x, y) = \beta \log$ で表すことができます。 $\pi_{\text{ref}}(y | x)$

証明の概略。任意の報酬関数 $r(x, y)$ を考え、それに対応する最適モデル $\pi(r(y | x) | x)$ を誘導する。これは式 4 で定義される。 r の同値類からの報酬関数は、上述の再パラメータ化を用いて表現できることを示す。射影 f を次のように定義する。

$$f(r; \pi_{\text{ref}}, \beta)(x, y) = r(x, y) - \beta \log \frac{\pi_{\text{ref}}(y | x) \exp}{y} - r(x, y) \beta \tag{8}$$

演算子 f は、報酬関数を π の分配関数の対数で正規化するだけです。追加された正規化項は接頭辞 x の関数にすぎないため、 $f(r; \pi_{\text{ref}}, \beta)(x, y)$ は $r(x, y)$ の同値類に属する報酬関数となります。最後に、 r を式 5 の右辺 (任意の報酬関数で $\pi(r(y|x))$ が成立する) に置き換えると、 $f(r; \pi_{\text{ref}}, \beta)(x, y) = \beta \log$ となります。つまり、射影 $\pi_{\text{ref}}(y|x)$. f は、 r の同値類に属する望ましい形式のメンバーを生成し、提案された再パラメータ化によって報酬モデルの一般性は失われません。

□

あるいは、定理 1 は、DPO 再パラメータ化によって各同値クラス内のどの報酬関数が選択されるかについて正確に指定するもの、つまり、次の条件を満たす報酬関数であると見ることができます。

$$\frac{\pi_{\text{ref}}(y | x) \exp}{y} - r(x, y) \beta = 1, \tag{9}$$

= $\pi(y|x)$. Thm を使用。 1 再パラメータ化。

すなわち、 $\pi(y | x)$ は有効な分布です (確率は正で、合計は 1 になります) 。しかし、式 4 に従うと、式 9 は報酬関数 $r(x, y)$ によって誘導される最適方策の分配関数であることがわかります。DPO アルゴリズムの重要な洞察は、制約が不十分なブラケット-ルース (特にブラッドリー-テリー) の選択モデル群に特定の制約を課することで、表現可能な報酬モデルのクラスを維持しながら、式 4 の最適方策をすべてのプロンプト x に対して明示的に解析的に扱えるようにできることです。

5.2 アクタークリティカルアルゴリズムの不安定性

また、このフレームワークを使用して、PPO などの RLHF で使用される標準的なアクタークリティカルアルゴリズムの不安定性を診断することもできます。RLHF バイブラインに従い、セクション 3 で概説した RL の微調整ステップに焦点を当てます。セクション 3 で概説した制約付き RL 問題に対する推論としての制御フレームワーク[22]との関連を描くことができます。パラメータ化されたモデル $\pi_{\theta}(y | x)$ を仮定し、 $DKL[\pi_{\theta}(y|x) || \pi_{\text{ref}}(y | x)]$ を最小化します。ここで、 π は報酬関数 $r(y, x)$ によって誘導される式 7 からの最適ポリシーです。いくつかの代数により、これは最適化目的につながります。

$$\max_{\theta} \mathbb{E} \pi_{\theta}(y|x) r(x, y) - \beta \log \frac{\pi_{\text{ref}}(y | x) \exp}{y} - r(x, y) \beta - \beta \log \frac{\pi_{\theta}(y | x) -}{\pi_{\text{ref}}(y | x)} \tag{10}$$

$f(r, \pi_{\text{ref}}, \beta)$

これは、先行研究[51, 40, 1, 28]で r の報酬クラスに DPO 相当の報酬を使用して最適化されたのと同じ目的関数です。この設定では、 $f(r, \pi_{\text{ref}}, \beta)$ の正規化項を参照ポリシー π_{ref} のソフト価値関数として解釈できます。この項は最適解には影響しませんが、これがないと目的関数のポリシー勾配の分散が大きくなり、学習が不安定になる可能性があります。学習済み価値関数を使用して正規化項に対応することはできますが、最適化が難しい場合があります。あるいは、先行研究では、基本的に正規化項の単一サンプルのモンテカルロ推定である、人間による完了ベースラインを使用して報酬を正規化しています。対照的に、DPO の再パラメータ化では、ベースラインを必要としない報酬関数が生成されます。

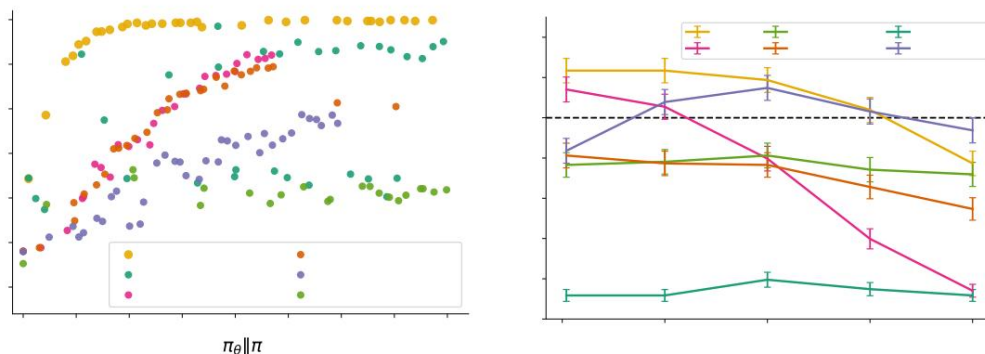


図2 左:期待報酬と参照ポリシーに対するKLのフロンティア。DPOはすべてのKL値に対して最高の期待報酬を提供し、最適化の質を示しています。右:GPT-4を評価器として使用したTL;DR要約の勝率と人間による要約の比較。DPOは要約においてPPOの最高性能を上回り、サンプリング温度の変化に対してより堅牢です。

6つの実験

このセクションでは、DPO が好みから直接ポリシーをトレーニングする能力を経験的に評価します。まず、適切に制御されたテキスト生成設定で、PPO などの一般的な好み学習アルゴリズムと比較して、DPO は報酬の最大化と KL ダイバージェンスの最小化を基準ポリシーとどれだけ効率的にトレードオフするかを尋ねます。次に、より大規模なモデルと、要約や対話などのより難しい RLHF タスクで DPO のパフォーマンスを評価します。ハイパーパラメータの調整がほとんどない場合、DPO は PPO を使用した RLHF などの強力なベースラインと同等かそれ以上のパフォーマンスを発揮する傾向があり、学習された報酬関数の下でN 個のサンプルされた軌跡のうち最良のものを返すことがわかりました。これらの結果を示す前に、実験のセットアップについて説明します。追加の詳細は付録 C にあります。

タスク。私たちの実験では、3つの異なる自由形式のテキスト生成タスクを調査します。すべての実験で、(i) (i) アルゴリズムは嗜好のデータセット $D = x$ からポリシーを学習します。制御された感情生成では、 x は IMDB データセットのレビューの接頭辞であり、ポリシーは肯定的な感情を持つ y を生成する必要があります。制御された評価を実行するために、この実験では、事前学習済みの感情分類器²を使用して、世代にわたって嗜好のペアを生成します。ここで、 $y_w > p(\text{positive} | x, y)$ です。SFTについては、IMDB データセットのトレーニング分割からのレビューで収束するまで GPT-2-large を微調整します(詳細は App C.1 を参照)。要約すると、 x は Reddit のフォーラム投稿であり、ポリシーは投稿の要点の要約 y を生成する必要があります。先行研究に従い、Reddit TL;DR要約データセット[43]とStiennonら³が収集した人間の嗜好を使用します。RLHF用のTRLX [44]フレームワークを使用して、人間が書いたフォーラム投稿の要約2で微調整されたSFTモデルを使用します。人間の嗜好データセットは、Stiennonらによって、異なるが同様に訓練されたSFTモデルのサンプルから収集されました。最後に、シングルターンの対話では、 x は人間のクエリであり、天体物理学に関する質問から人間関係のアドバイスの要求まで、何でもかまいません。ポリシーは、ユーザーのクエリに対して魅力的で役立つ応答 y を生成する必要があります。私たちは、人間と自動アシスタントの間の17万回の対話を含む、人間にとって役立つおよび無害な対話データセット[1]を使用します。各トランスクリプトは、大規模な (ただし未知の) 言語モデルによって生成された応答のペアと、人間の好みの応答を示す選好ラベルで終わります。この設定では、事前学習済みのSFTモデルは利用できません。したがって、私たちは、優先補充のみに基づいて既製の言語モデルを微調整し、SFT モデルを形成します。

評価。本実験では、2つの異なる評価手法を用いる。制約付き報酬最大化目標の最適化における各アルゴリズムの有効性を分析するため、制御された感情生成設定において、各アルゴリズムの達成報酬のフロンティアと参照ポリシーからのKLダイバージェンスを用いて評価する。このフロンティアは、グラウンドトゥールズ報酬関数 (感情分類器) にアクセスできるため計算可能である。しかし、現実世界ではグラウンドトゥールズ報酬関数は不明であるため、要約と単発対話設定における要約の質と応答の有用性に関する人間による評価の代理としてGPT-4を用い、ベースラインポリシーに対する勝率を用いてアルゴリズムを評価する。要約については、テストセット内の参照要約をベースラインとして用いる。対話については、テストセット内の好ましい応答を用いる。

²https://huggingface.co/CarperAI/openai_summarize_tldr_sft




図3 左:GPT-4によって計算されたAnthropic-HHワンステップ対話の勝率。DPOは、Anthropic-HHテストセットにおいて選択された要約に対して改善を示した唯一の手法です。右:トレーニング過程における異なるサンプリング温度での勝率。データセットラベルに対するDPOの改善は、異なるサンプリング温度でのトレーニング過程を通じてほぼ安定しています。

テストデータセットをベースラインとして使用した。既存の研究では、LMは既存の評価指標よりも優れた自動評価ツールになり得ることが示唆されているが[10]、6.4節ではGPT-4を評価ツールとして使用することを正当化するために人間を対象とした研究を行った。その結果、GPT-4の判断は人間の判断と強く相関しており、人間とGPT-4の一致率は通常、人間同士のAIモデルの一致率と同等かそれ以上であることがわかった。

方法。DPOに加えて、言語モデルを人間の好みに合わせるようにトレーニングする既存のアプローチをいくつか評価する。最も単純な方法として、要約タスクではGPT-J [45]を用いたゼロショットプロンプト、対話タスクではPythia-2.8B [3]を用いた2ショットプロンプトを検討する。さらに、SFTモデルとPreferred-FTを評価する。Preferred-FTは、SFTモデル（制御された感情と要約）または汎用LM（シングルターン対話）から選択された補完ylに基づいて、教師あり学習で微調整されたモデルである。もう1つの疑似教師あり手法はUnlikelihood [46]であり、これはylに割り当てられる確率を最大化し、ylに割り当てられる確率を最小化するようにポリシーを最適化するだけである。「可能性の低さ」という項にはオプションの係数 $\alpha \in [0, 1]$ を使用する。また、選好データから学習した報酬関数を使用するPPO [39]と、制御された感情設定で利用可能な真の報酬関数から学習するオラクルであるPPO-GTも検討します。感情実験では、PPO-GTの2つの実装を使用します。1つは既存バージョン[44]で、もう1つは報酬を正規化し、ハイパーパラメータをさらに調整してパフォーマンスを向上させる修正バージョンです（学習した報酬で「通常の」PPOを実行するときにもこれらの修正を使用します）。最後に、SFTモデル（または対話のPreferred-FT）からN個の応答をサンプリングし、選好データセットから学習した報酬関数に従って最高スコアの応答を返す、Best of Nベースラインを検討します。この高性能な方法は、報酬モデルの品質とPPO最適化を切り離しますが、テスト時にすべてのクエリに対してN個の完了をサンプリングする必要があるため、中程度のNであっても計算上非実用的です。

6.1 DPO は RLHF 目標をどの程度最適化できますか？

一般的な RLHF アルゴリズムで使用される KL 制約報酬最大化目標は、ポリシーが参照ポリシーから大きく逸脱しないように制限しながら、報酬の活用をバランスをとります。

したがって、アルゴリズムを比較する場合、達成された報酬と KL の差異の両方を考慮する必要があります。わずかに高い報酬を達成しても、KL が大幅に高くなることは必ずしも望ましいとは限りません。

図2は、感情設定におけるさまざまなアルゴリズムの報酬 KL フロンティアを示しています。各アルゴリズムに対して、実行ごとに異なるポリシー保守性のハイパーパラメータを使用して、複数のトレーニング実行を実行します（PPO の場合はターゲット $KL \in \{3, 6, 9, 12\}$ 、可能性が低い場合は $\beta \in \{0.05, 0.1, 1, 5\}$ 、 $\alpha \in \{0.05, 0.1, 0.5, 1\}$ 、preferred-FT の場合はランダムシード）。このスweepには合計 22 回の実行が含まれます。収束までの 100 回のトレーニング ステップごとに、一連のテスト プロンプトで各ポリシーを評価し、真の報酬関数での平均報酬と、参照ポリシー KL ($\pi \parallel \pi_{ref}$) を使用した平均シーケンスレベル KL3 を計算します。DPO ははるかに効率的なフロンティアを生成し、低い KL を達成しながら最高の報酬を達成することがわかります。まず、DPO と PPO は同じ目的を最適化しますが、DPO の方がはるかに効率的です。

3つあり、タイムステップごとの KL ダイバージェンスの合計です。

DPOの報酬とKLのトレードオフはPPOを厳密に支配します。第二に、PPOがグラウンドトゥールズ報酬にアクセスできる場合でも、DPOはPPOよりも優れたフロンティアを実現します（PPO-GT）。

6.2 DPO は実際の嗜好データセットに拡張できますか？

次に、要約とシングルターン対話におけるDPOの微調整パフォーマンスを評価します。要約の場合、ROUGEなどの自動評価指標は人間の好みとの相関が低い場合があります[40]、以前の研究では、人間の好みに基づいてPPOを使用してLMを微調整すると、より効果的な要約を提供できることがわかっています。TL;DR要約データセットのテスト分割で補完をサンプリングし、テストセット内の参照補完に対する平均勝率を計算することにより、さまざまな手法を評価します。すべての手法の補完は、0.0から1.0まで変化する温度でサンプリングされ、勝率は図2（右）に示されています。DPO、PPO、およびPreferred-FTはすべて、同じGPT-J SFTモデル4を微調整します。DPOは温度0.0で約61%の勝率を持ち、最適なサンプリング温度0.0でのPPOの57%のパフォーマンスを上回っていることがわかりました。DPOは、ベストオブNベースラインと比較して高い最大勝率も達成しています。なお、DPOのβハイパーパラメータを有意に調整していないため、これらの結果はDPOの潜在能力を過小評価している可能性があります。さらに、DPOはPPOよりもサンプリング温度に対してはかにロバストであることがわかりました。PPOは高温下ではベースGPT-Jモデルの性能まで低下する可能性があります。

Preferred-FTはSFTモデルと比べて大幅な改善は見られませんでした。また、セクション6.4では、人間による評価においてDPOとPPOを直接比較しましたが、温度0.25のDPOサンプルは、温度0のPPOサンプルよりも58%高い割合で好まれました。

シングルターン対話では、Anthropic HHデータセット[1]のテスト分割のサブセットに対して、人間とアシスタントのインタラクションを1ステップ実行して、さまざまな手法を評価します。GPT-4の評価では、テストで推奨される補完を基準として使用し、さまざまな手法の勝率を計算します。このタスクには標準的なSFTモデルがないため、事前学習済みのPythia-2.8Bから開始し、Preferred-FTを使用して、選択された補完で参照モデルを学習し、補完がモデルの分布内に収まるようにしてから、DPOを使用して学習します。また、128個のPreferred-FT補完のベスト（このタスクでは128個の補完でBest of Nベースラインがプラトーに達しました。付録図4を参照）とPythia-2.8Bベースモデルの2ショットプロンプトバージョンと比較し、各手法の最高パフォーマンスの温度でDPOが同等かそれ以上のパフォーマンスを発揮することがわかりました。また、PPOを用いてAnthropic HHデータセットで学習させたRLHFモデルも評価しましたが、ベースとなるPythia-2.8Bモデルよりも優れたパフォーマンスを発揮するプロンプト温度やサンプリング温度は見つかりませんでした。TL;DRの結果と、両手法が同じ報酬関数を最適化するという事実に基づき、Best of 128はPPOレベルのパフォーマンスの大まかな代替手法であると考えています。全体として、DPOは、Anthropic HHデータセットにおける推奨補完よりも優れたパフォーマンスを発揮し、計算負荷の高いBest of 128ベースラインと同等以上のパフォーマンスを提供する、計算効率の高い唯一の手法です。最後に、図3は、DPOが比較的に最高パフォーマンスに収束することを示しています。

6.3 新しい入力分布への一般化

分布シフト下でのPPOとDPOのパフォーマンスをさらに比較するために、CNN/DailyMailデータセット[26]のテスト分割に含まれるニュース記事という異なる分布でのReddit TL;DR要約実験からのPPOとDPOポリシーを、TL;DRからの最良のサンプリング温度（0と0.25）を使用して評価しました。結果を表1に示します。Reddit TL;DRに使用したものと同じGPT-4(C)プロンプトを使用して、データセット内のグラウンドトゥールズ要約に対するGPT-4勝率を計算しましたが、「フォーラム投稿」という単語を「ニュース記事」に置き換えました。

勝率と実際の結果	
アルゴリズム温度 0	温度0.25
DPO 0.36 PPO 0.26	0.31 0.23

表1: 分布外CNN / Daily Mail入力記事に対するGPT-4勝率とグラウンドトゥールズサマリーの比較。

この新しい分布において、DPOは引き続きPPOポリシーを大幅に上回るパフォーマンスを示しました。この実験は、DPOがPPOが使用する追加のラベルなしReddit TL;DRプロンプトを使用していないにもかかわらず、DPOポリシーがPPOポリシーと同様に一般化できることを示唆する初期証拠を示しています。

⁴https://huggingface.co/CarperAI/openai_summarize_tldr_sft
⁵https://huggingface.co/CarperAI/reciprocate_ppo_hh_pythia-6B
⁶<https://github.com/CarperAI/trlx/tree/main/examples/hh>

6.4 GPT-4の判断を人間の判断で検証する

GPT-4の判断の信頼性を検証するために、以下の結果を用いて人間を対象とした研究を実施しました。TL;DR要約実験と2つの異なるGPT-4プロンプト。GPT-4 (S) (simple)プロンプトは、どちらの要約が重要な情報をより適切に要約しているかを尋ねるシンプルなものです。GPT-4 (C) (簡潔) プロンプトでは、どちらの要約がより簡潔であるかを尋ねます。GPT-4は、人間がGPT-4 (S)プロンプトで回答するよりも、より長く、より反復的な要約を好むことがわかったため、このプロンプトを評価しました。完全なプロンプトについては、付録C.2を参照してください。

最高値 (DPO、温度0.25)、最低値 (PPO、温度1.0)、および中程度の性能 (SFT、温度0.25)の方法で多様なサンプル品質を網羅することを目指します。これら 3 つの方法は、貪欲にサンプリングされた PPO (最もパフォーマンスの高い温度) と比較されます。両方のプロンプトでGPT-4は人間が同意するのと同じくらい頻繁に人間に同意する。GPT-4は人間の評価の適切な代理ツールである可能性を示唆している (限られた人間の評価者による評価は、DPOとPPO-1の比較にのみ複数の人間の判断を収集します。全体的に、GPT-4 (C) プロンプトは一般的に勝利を提供します。人間をより代表する割合。したがって、セクション6.2の主な結果にはこのプロンプトを使用します。人間を対象とした研究に関する追加の詳細、評価者および人間のボランティアのリストについては、付録D.3を参照してください。

	DPO SFT PPO-1		
N人の回答者	272	122	199
GPT-4 (S) 勝率 47		27	13
GPT-4 (C) 勝率 54		32	12
人間の勝率 58%		43	17
GPT-4 (S)-Hは一致	70	77	86
GPT-4 (C)-Hは一致する	67	79	85
Hは同意する	65	-	87

表2: 人間とGPT-4の勝率の比較
TL;DR要約サンプルにおける判断ごとの一致。人間はGPT-4とほぼ同程度一致している。それらは互いに一致する。各実験は、記載された方法の要約を比較する。温度 0 の PPO からの要約付き。

7 議論

好みからの学習は、有能で整合した言語を訓練するための強力なスケーラブルなフレームワークである。モデル。言語モデルを訓練するためのシンプルで訓練パラダイムであるDPOを導入しました。強化学習なしで好みを学習する。好み学習問題を強制するのではなく既製のRLアルゴリズムを使用するために標準的なRL設定にDPOがマッピングを特定する言語モデルのポリシーと報酬関数を関連付けることで、言語モデルを訓練して強化学習なしで、単純なクロスエントロピー損失で人間の好みを直接満たすまたは一般性の喪失。ハイパーパラメータの調整をほとんど行わずに、DPOは同等かそれ以上の性能を発揮する。既存のRLHFアルゴリズム (PPOに基づくものを含む)よりも、DPOは大幅に削減されます。人間の好みからより多くの言語モデルをトレーニングすることに対する障壁。

限界と今後の課題。私たちの結果は、今後の研究に向けていくつかの重要な疑問を提起しています。DPOポリシーは、明示的な報酬から学習する場合と比較して、分布外に一般化しますか？機能？私たちの初期の結果は、DPOポリシーがPPOベースのモデルと同様に一般化できることを示唆している。しかし、より包括的な研究が必要です。例えば、自己ラベル付けによるトレーニングは、DPOポリシーは、ラベルのないプロンプトを同様に効果的に活用していますか？別の観点から、報酬はどのように機能しますか？過剰最適化は直接的な好みの最適化設定で現れ、わずかな減少は図3右のパフォーマンスの例ですか？さらに、モデルを評価する際に6Bパラメータ、最先端のモデルにDPOをスケーリングする探究は桁違いに大きいこれは今後の研究にとって刺激的な方向性です。評価に関しては、計算された勝率はGPT-4による結果はプロンプトの影響を受ける。今後の研究では、質の高い回答を引き出す最良の方法を研究するかもしれない。自動化システムからの判断。最後に、DPOはトレーニング以外にも多くの応用が可能である。他のモダリティでの生成モデルのトレーニングを含む、人間の好みからの言語モデル。

謝辞

EMIは、ナイト・ヘネシー大学院奨学金の資金提供に深く感謝いたします。CFとCM CIFARフェローです。本研究はスタンフォード・アクセラレーター・フォー・ラーニングの支援を受けて実施されました。(SAL)とスタンフォード人間中心人工知能研究所 (HAI)生成AI 未来の学習シード助成金プログラム。スタンフォード基礎モデル研究センター (CRFM)は、本研究の実験に使用された計算リソースの一部を提供しました。本研究 ONR助成金N00014-20-1-2675により一部支援されました。

参考文献

- [1] Y. Bai, A. Jones, K. Ndousse, A. Askell, A. Chen, N. DasSarma, D. Drain, S. Fort, D. Ganguli, T. Henighan, N. Joseph, S. Kadavath, J. Kernion, T. Conerly, S. El-Showk, N. Elhage, Z. Hatfield- Dodds, D. Hernandez, T. Hume, S. Johnston, S. Kravec, L. Lovitt, N. Nanda, C. Olsson, D. Amodei, T. Brown, J. Clark, S. McCandlish, C. Olah, B. Mann, J. Kaplan.人間のフィードバックからの強化学習による、役に立つ無害なアシスタントのトレーニング、2022年。
- [2] Y.バイ、S.カダバス、S.クンドウ、A.アスケル、J.カーニオン、A.ジョーンズ、A.チェン、A.ゴールディ、A.ミルホセイニ、C.マッキノン、C.チェン、C.オルソン、C.オラー、D.ヘルナンデス、D.ドレイン、D.ガングリ、D.リー、E.トランジョンソン、E.ペレス、J.カー、J. ミューラー、J. ラディッシュ、J. ランダウ、K. シンドウス、K. ルコスイト、L. ロビット、M. セリット、N. エルハーゲ、N. シーファ、N. メルカド、N. ダサルマ、R. ラセンビー、R. ラーソン、S. リンガー、S. ジョンストン、S. クラベック、SE ショーク、S. フォート、T. ランハム、T. テレン・ロートン、T. コナリー、T. ヘニガン、T. ヒューム、S. R. ボウマン、Z. ハットフィールド=ドッズ、B. マン、D. アモデイ、N. ジョセフ、S. マッキヤンドリッシュ、T. ブラウン、J. カプラン。「憲法上のAI :AIフィードバックからの無害性」、2022年。
- [3] S. Biderman, H. Schoelkopf, Q. Anthony, H. Bradley, K. O'Brien, E. Hallahan, MA Khan, S. Purohit, US Prashanth, E. Raff, A. Skowron, L. Sutawika, O. van der Wal, Python :トレーニングとスケールリングにわたる大規模言語モデルの分析スイート、2023年。
- [4] H. BongとA. Rinaldo. Bradley-Terry-LuceモデルにおけるMLEの存在と一貫性に関する一般化された結果. 国際機械学習会議, 2022. arXiv:2110.11487.
- [5] RA BradleyとME Terry. 不完全ブロックデザインの順位分析 :I. 一対比較法. Biometrika, 39(3/4):324-345, 1952. doi: <https://doi.org/10.2307/2334029>.
- [6] T. Brown, B. Mann, N. Ryder, M. Subbiah, JD Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, J. Sutskever, D. Amodei.言語モデルは少数ショット学習器である。H. Larochelle, M. Ranzato, R. Hadsell, M. Balcan, および H. Lin 編, 『Advances in Neural Information Processing Systems』第33巻, 1877 ~ 1901 ページ。Curran Associates, Inc., 2020 年。URL https://proceedings.neurips.cc/paper_files/paper/2020/file/1457c0d6bfc4967418bfb8ac142f64a-Paper.pdf。
- [7] T. Brown, B. Mann, N. Ryder, M. Subbiah, JD Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, et al. 「言語モデルは少数ショット学習器である」神経情報処理システムの進歩, 33:1877-1901, 2020年。
- [8] S. Bubeck, V. Chandrasekaran, R. Eldan, J. Gehrke, E. Horvitz, E. Kamar, P. Lee, Y. T. Lee, Y. Li, S. Lundberg, H. Ori, H. Palangi, M. T. Ribeiro, および Y. Zhang.汎用人工知能の火花: GPT-4 による初期実験, 2023 年。arXiv プレプリント arXiv:2303.12712。
- [9] R. Busa-Fekete, B. Szörényi, P. Weng, W. Cheng, E. Hüllermeier. 選好に基づく強化学習 :選好に基づくレーシングアルゴリズムを用いた進化的直接方策探索. 機械学習, 97(3):327-351, 2014年7月. doi: 10.1007/s10994-014-5458-8. URL <https://doi.org/10.1007/s10994-014-5458-8>.
- [10] Y. Chen, R. Wang, H. Jiang, S. Shi, R.-L. Xu. 「大規模言語モデルを用いた参照フリーテキスト品質評価の検討 :予備的な実証研究」arXiv, abs/2304.00723, 2023.
- [11] A. Chowdhery, S. Narang, J. Devlin, M. Bosma, G. Mishra, A. Roberts, P. Barham, H. W. Chung, C. Sutton, S. Gehrmann, et al. Palm: パスウェイによる言語モデルのスケールリング。arXiv プレプリント arXiv:2204.02311, 2022年。
- [12] PF Christiano, J. Leike, T. Brown, M. Martic, S. Legg, D. Amodei. 「人間の嗜好からの深層強化学習」, J. Guyon, U. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, R. Garnett 編, 『Advances in Neural Information Processing Systems』第30巻, Curran Associates, Inc., 2017年。URL https://proceedings.neurips.cc/paper_files/paper/2017/file/d5e2c0adad503c91f91df240d0cd4e49-Paper.pdf。

- [13] HW Chung, L. Hou, S. Longpre, B. Zoph, Y. Tay, W. Fedus, Y. Li, X. Wang, M. Dehghani, S. Brahma, A. Webson, SS Gu, Z. Dai, M. Suzgun, X. Chen, A. Chowdhery, A. Castro-Ros, M. Pellat, K. Robinson, D. Valter, S. Nanang, G. Mishra, A. Yu, V. Zhao, Y. Huang, A. Dai, H. Yu, S. Petrov, EH Chi, J. Dean, J. Devlin, A. Roberts, D. Zhou, QV Le, J. Wei.
命令微調整言語モデルのスケーリング, 2022年。
- [14] M. Dudík, K. Hofmann, RE Schapire, A. Slivkins, M. Zoghi. 文脈上の決闘盗賊。
P. Grünwald, E. Hazan, S. Kale編, 『Proceedings of The 28th Conference on Learning Theory』, 機械学習研究論文
集第40巻, 563~587ページ, バリ, フランス, 2015年7月3~6日。PMLR。URL <https://proceedings.mlr.press/v40/Dudik15.html>。
- [15] D. Go, T. Korbak, G. Kruszewski, J. Rozen, N. Ryu, M. Dymetman. f-ダイバージェンス最小化による言語モデルと嗜好の
整合. 第40回国際機械学習会議ICML'23議事録. JMLR.org, 2023.
- [16] A. Jain, B. Wojcik, T. Joachims, A. Saxena. 反復的改善によるマニピュレータの軌道選択の学習. C. Burges, L. Bottou,
M. Welling, Z. Ghahramani, K. Weinberger編, Advances in Neural Information Processing Systems, volume 26.
Curran Associates, Inc., 2013. URL https://proceedings.neurips.cc/paper_files/paper/2013/file/c058f544c737782deacefa532d9add4c-Paper.pdf.
- [17] N. Jaques, S. Gu, D. Bahdanau, JM Hernández-Lobato, RE Turner, D. Eck. 「シーケンスチューター :KL制御を用いたシー
ケンス生成モデルの保守的なファインチューニング」国際機械学習会議, 1645-1654ページ。PMLR, 2017年。
- [18] N. Jaques, JH Shen, A. Ghandeharioun, C. Ferguson, A. Lapedriza, N. Jones, SS Gu, R. Picard. オフライン強化学習に
よる人間中心の対話トレーニング。arXivプレプリント arXiv:2010.05848, 2020年。
- [19] T. Korbak, H. Elsahar, G. Kruszewski, M. Dymetman. 破滅的な忘却のない言語モデルの微調整のための強化学習と分布マ
ッチングについて. S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, A. Oh編, Advances in Neural Information
Processing Systems, 第35巻, 16203-16220ページ. Curran Associates, Inc., 2022. URL https://proceedings.neurips.cc/paper_files/paper/2022/file/67496dfa96afddab795530cc7c69b57a-Paper-Conference.pdf.
- [20] J. Kreutzer, J. Uyheng, S. Riezler. シーケンスツーシーケンス強化学習における人間のバンディットフィードバックの信頼性と
学習可能性. 計算言語学協会第56回年次会議議事録 (第1巻 :長編論文), 1777-1788ページ, メルボルン, オーストラリア,
2018年7月. 計算言語学協会. doi: 10.18653/v1/P18-1165. URL <https://aclanthology.org/P18-1165>.
- [21] A. Kupcsik, D. Hsu, WS Lee. 人間のフィードバックからのロボットから人間への動的な物体の受け渡しの学習, 161-176ペー
ジ。Springer International Publishing, 2018年1月。ISBN 978-3-319-51531-1. doi: 10.1007/978-3-319-51532-8_10。
- [22] S. Levine. 強化学習と制御における確率推論 :チュートリアルとレビュー、
2018年。
- [23] RDルール 「個人の選択行動 :理論的分析」クーリエコーポレーション, 2012年。
- [24] AL Maas, RE Daly, PT Pham, D. Huang, AY Ng, C. Potts. 感情分析のための単語ベクトルの学習. 第49回計算言語学協会年
次会議論文集 「人間言語技術」, 142-150ページ, オレゴン州ポートランド, 米国, 2011年6月. 計算言語学協会. URL <http://www.aclweb.org/anthology/P11-1015>.
- [25] S. Mishra, D. Khashabi, C. Baral, H. Hajishirzi. 自然言語クラウドソーシング指示によるクロスタスク一般化. 計算言語学協
会第60回年次会議議事録 (第1巻 :長編論文), 3470-3487ページ, ダブリン, アイルランド, 2022年5月. 計算言語学協会.
doi: 10.18653/v1/2022.acl-long.
244. URL <https://aclanthology.org/2022.acl-long.244>.

- [26] R. Nallapati, B. Zhou, C. dos Santos, Ç. Gülçehre, B. Xiang. シーケンスツーシーケンスRNNを用いた抽象テキスト要約とその応用.第20回計算自然言語学習に関するSIGNLL会議論文集,280-290ページ,ベルリン,ドイツ,2016年8月.
計算言語学協会. doi: 10.18653/v1/K16-1028. URL <https://aclanthology.org/K16-1028>.
- [27] D. Narayanan, M. Shoenybi, J. Casper, P. LeGresley, M. Patwary, V. Korthikanti, D. Vainbrand, P. Kashinkunti, J. Bernauer, B. Catanzaro, A. Phanishayee, M. Zaharia. 「Megatron-LMを用いたGPUクラスター上での大規模言語モデルの効率的なトレーニング」国際高性能コンピューティング、ネットワーキング、ストレージ、分析会議SC '21の議事録、ニューヨーク、ニューヨーク州、米国、2021年。Association for Computing Machinery. ISBN 9781450384421. doi: 10.1145/3458817.3476209. URL <https://doi.org/10.1145/3458817.3476209>.
- [28] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. Christiano, J. Leike, R. Lowe. 人間のフィードバックによる指示に従う言語モデルのトレーニング. S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, A. Oh編, Advances in Neural Information Processing Systems, 第35巻, 27730-27744ページ.
- Curran Associates, Inc., 2022. URL https://proceedings.neurips.cc/paper_files/paper/2022/file/b1efde53be364a73914f58805a001731-Paper-Conference.pdf.
- [29] R. Paulus, C. Xiong, R. Socher. 抽象要約のための深層強化モデル.国際学習表現会議,2018年. URL <https://openreview.net/forum?id=HkAClQgA->.
- [30] XB Peng, A. Kumar, G. Zhang, S. Levine. 「アドバンテージ加重帰帰 :単純およびスケーラブルなオフポリシー強化学習」arXivプレプリントarXiv:1910.00177,2019.
- [31] J. Peters and S. Schaal. 報酬重み付き帰法による強化学習による操作空間制御. 第24回国際機械学習会議論文集, 745-750ページ, 2007年.
- [32] RL Plackett. 順列分析. 王立統計学会誌. シリーズC (応用統計), 24(2):193-202, 1975. doi: <https://doi.org/10.2307/2346567>.
- [33] A. Radford, J. Wu, R. Child, D. Luan, D. Amodei, I. Sutskever. 言語モデルは教師なしマルチタスク学習者, 2019年. Ms., OpenAI.
- [34] R. Ramamurthy, P. Ammanabrolu, K. Brantley, J. Hessel, R. Sifa, C. Bauckhage, H. Hajishirzi, Y. Choi. 「強化学習は自然言語処理に適するか適さないか :自然言語ポリシー最適化のためのベンチマーク、ベースライン、および構成要素」第11回国際学習表現会議,2023年. URL <https://openreview.net/forum?id=8aHdzs2uUyB>.
- [35] M. Ranzato, S. Chopra, M. Auli, W. Zaremba. 「リカレントニューラルネットワークによるシーケンスレベルの学習」CoRR, abs/1511.06732, 2015年.
- [36] D. Sadigh, A. D. Dragan, S. Sastry, S. Seshia. 能動的選好に基づく学習報酬関数. Robotics: Science and Systems (RSS), 2017年.
- [37] A. Saha, A. Pacchiano, J. Lee, 「Dueling rl :軌道設定による強化学習」, F. Ruiz, J. Dy, J.-W. van de Meent編, 「Proceedings of The 26th International Conference on Artificial Intelligence and Statistics」, 機械学習研究論文集第206巻, 6263-6289ページ, PMLR, 2023年4月25~27日. URL <https://proceedings.mlr.press/v206/saha23a.html>
- [38] V. サン, A. ウェブソン, C. ラッフエル, S. バッハ, L. スタウィカ, Z. アリヤフェアイ, A. チャフィン, A. スティグラー, A. ラジャ, M. デイ, MS パーリ, C. シュー, U. タッカー, SS シャルマ, E. シュチェクラ, T. キム, G. チャプラニ, N. ナヤック, D. ダッタ, J. チャン, MT-J. Jiang, H. Wang, M. Manica, S. Shen, ZX Yong, H. Pandey, R. Bawden, T. Wang, T. Neeraj, J. Rozen, A. Sharma, A. Santilli, T. Fevry, JA Fries, R. Teehan, TL Scao, S. Biderman, L. Gao, T. Wolf, AM Rush. マルチタスクプロンプトトレーニングによりゼロショットタスクの汎化が可能に. 国際学習表現会議, 2022. URL <https://openreview.net/forum?id=9Vrb9D0WI4>.

- [39] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, O. Klimov. 近接政策最適化アルゴリズム, 2017年。
- [40] N. Stiennon, L. Ouyang, J. Wu, D. M. Ziegler, R. Lowe, C. Voss, A. Radford, D. Amodei, および P. クリステアノー. 人間のフィードバックから要約を学ぶ, 2022年。
- [41] R. ソビラン, D. D. フレイタス, J. ホール, N. シャジーア, A. クルシュレシュタ, H.-T. Cheng, A. Jin, T. Bos, L. Baker, Y. Du, Y. Li, H. Lee, H. S. Zheng, A. Ghafouri, M. Menegali, Y. Huang, M. Krikun, D. Lepikhin, J. Qin, D. Chen, Y. Xu, Z. Chen, A. Roberts, M. Bosma, V. Zhao, Y. Zhou, C.-C. Chang, I. クリヴォコン, W. ラッシュ, M. ビケット, P. スリニバサン, L. マン, K. マイヤー-ヘルスターン, M. R. モリス, T. ドーシ, R. D. サントス, T. デューク, J. ソラカー, B. ゼフェンベルゲン, V. ブラバカラ, M. ディアス, B. ハッチンソン, K. オルソン, A. モリーナ, E. ホフマン ジョン, J. Lee, L. Aroyo, R. Rajakumar, A. Butryna, M. Lamm, V. Kuzmina, J. Fenton, A. Cohen, R. Bernstein, R. Kurzweil, B. Agüera-Arcas, C. Cui, M. Croak, E. Chi, および Q. Le. Lambda: ダイアログ アプリケーションの言語モデル, 2022 年。
- [42] H. トウヴロン, T. ラヴリル, G. イザカード, X. マーティネット, M.-A. ラシヨ, T. ラクロワ, B. ロジエール, N. ゴヤル, E. ハンプロ, F. アズハル, 他 Llama: オープンで効率的な基礎言語モデル. arXiv プレプリント arXiv:2302.13971, 2023。
- [43] M. Völske, M. Potthast, S. Syed, B. Stein. TL;DR: Reddit マイニングによる自動要約学習. 要約における新境地ワークショップ議事録, 59~63 ページ, コペンハーゲン, デンマーク, 2017 年 9 月. 計算言語学協会. doi: 10.18653/v1/W17-4508. URL <https://aclanthology.org/W17-4508>.
- [44] L. フォン ヴェラ, J. トウ, 往復, S. マティアナ, A. ハブリラ, 猫の州, L. カトリカート, アラン, D. V. Phung, A. Thakur, A. Bukhtiyarov, aaronmm, F. Milo, Daniel, D. King, D. Shin, E. Kim, J. Wei, M. Romero, N. Pochinkov, O. Sanseviero, R. Adithyan, S. Siu, T. Simonini, V. Blagojevic, X. Song, Z. Witten, alexandremuzio, および crumb. CarperAI/trlx: v0.6.0: LLaMa (Alpaca), ベンチマーク Util, T5 ILQL, テスト, 2023 年 3 月. URL <https://doi.org/10.5281/zenodo.7790115>.
- [45] B. 王と A. 小松崎. GPT-J-6B: 60 億パラメータの自己回帰言語モデル. <https://github.com/kingoflolz/mesh-transformer-jax>, 2021 年 5 月。
- [46] S. ウェレック, I. クリコフ, S. ローラー, E. ディナン, K. チョー, および J. ウェストン. ニューラルテキスト生成可能性の低いトレーニング. arXiv プレプリント arXiv:1908.04319, 2019。
- [47] R. J. Williams. コネクション強化学習のための単純な統計的勾配追従アルゴリズム. Mach. Learn., 8(3-4):229-256, 1992 年 5 月. ISSN 0885-6125. doi: 10.1007/BF00992696. URL <https://doi.org/10.1007/BF00992696>.
- [48] Y. Wu と B. Hu. 深層強化学習による首尾一貫した要約の抽出 第32回 AAAI 人工知能会議, 第30回革新的人工知能応用会議, および 第8回 AAAI 人工知能教育進歩シンポジウム 議事録, AAAI'18 / IAAI'18 / EAAI'18. AAAI Press, 2018 年. ISBN 978-1-57735-800-8。
- [49] X. Yan, C. Luo, C. A. Clarke, N. Craswell, E. M. Voorhees, P. Castells. 「決闘する盗賊としての人間の嗜好」第45回国際 ACM SIGIR 情報検索研究開発会議 議事録, SIGIR '22, 567-577 ページ, ニューヨーク, ニューヨーク州, 米国, 2022 年. Association for Computing Machinery. ISBN 9781450387323. doi: 10.1145/3477495.3531991. URL <https://doi.org/10.1145/3477495.3531991>.
- [50] Y. Yue, J. Broder, R. Kleinberg, T. Joachims. K-アーム盗賊問題. Journal of Computer and System Sciences, 78(5):1538-1556, 2012. ISSN 0022-0000. doi: <https://doi.org/10.1016/j.jcss.2011.12.028>. URL <https://www.sciencedirect.com/science/article/pii/S0022000012000281>. JCSS 特集号: クラウドコンピューティング 2011.
- [51] D. M. Ziegler, N. Stiennon, J. Wu, T. B. Brown, A. Radford, D. Amodei, P. Christiano, G. Irving. 人間の好みに基づいた言語モデルの微調整, 2020 年。

著者の貢献

すべての著者は、実験の設計、分析、反復、論文の執筆と編集、そしてプロジェクトの進捗の全般的な管理に貴重な貢献をしました。

RRはEMとの議論の中で自己回帰報酬モデルの使用を提案し、DPO目標値を導出し、アルゴリズムの理論的特性を証明し、関連セクションと付録を執筆しました。また、実験の計画についても提案と支援を行い、PPOと報酬学習のベースラインの一部に貢献しました。

ASは、PPOの代替として加重回帰法を使用するという議論を開始し、プロジェクト関連の組織を開始し、DPOと加重回帰および可能性の低さを関連付ける初期分析を書きました。DPO + ベースライン実装の設計と反復、DPOの初期探索的実験、実質的な実験の組織と設計(データセット、ベースライン、評価)、制御された感情生成と要約のためのモデルトレーニングと評価を主導しました。GPT-4評価(特に要約)の反復を設計しました。要約、予備試験/方法、実験への実質的な執筆貢献、他のセクションへの編集貢献を行いました。

EMは、自己回帰報酬関数の学習に関する初期の議論に意見を提供し、DPOの最初の実装を記述して最初のDPO実験を実行し、論文実験で使用する大規模な(要約と対話)DPOモデルをトレーニングし、初期のGPT-4勝率評価を実施して関連インフラストラクチャをセットアップし、人間研究の参加者を募集して実施し、結果を分析し、要約、序論、関連作業、議論、および実験の大部分を記述し、論文の残りの部分の編集を支援しました。

CF、CM、SEは研究を監督し、アイデアや実験を提案し、論文の執筆を支援しました。

数学的導出

A.1 KL制約付き報酬最大化目標の最適値の導出

この付録では、式4を導出します。式3と同様に、次の目的関数を最適化します。

最大 $\pi \quad \mathbb{E}_{x, y} \pi(r(x, y) - \beta \text{DKL}(\pi(y|x) || \pi_{\text{ref}}(y|x)))$ (11)

任意の報酬関数 $r(x, y)$ 、参照モデル π_{ref} 、および一般的な非パラメトリックポリシークラスの下で。

現在、次のようになっています。

最大 $\pi \quad \mathbb{E}_{x, y} \pi(r(x, y) - \beta \text{DKL}(\pi(y|x) || \pi_{\text{ref}}(y|x)))$

$= \max_{\pi} \mathbb{E}_x \mathbb{E}_y \pi(y|x) r(x, y) - \beta \log \pi_{\text{ref}}(y|x) \mathbb{1}_{r(x, y) \geq \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)}}$

$= \int_{\pi} \mathbb{E}_x \mathbb{E}_y \pi(y|x) \log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)} - \frac{\pi(y|x) \mathbb{1}_{\pi_{\text{ref}}(y|x) > \pi(y|x)}}{\log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)}} - \log Z(x)$ (12)

ここでパーティション関数は次のようになります。

$Z(x) = \int_y \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r(x, y) \right) dy$

分割関数は x と参照ポリシー π_{ref} のみの関数であり、ポリシー π には依存しないことに注意する。ここで、

$\pi(y|x) = \frac{\pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r(x, y) \right)}{Z(x)}$

ないため、有効な確率分布となる。したがって、式 12 の最終目的は次のように、 $\pi(y|x) \geq 0$ はすべての y に対して成り立ち、 $\sum_y \pi(y|x) = 1$ となる。 $Z(x)$ は π が y の関数であるように再構成できる。 $\pi(y|x) \min_{\pi} \mathbb{E}_x \mathbb{D}(\pi(y|x) \parallel \pi(y|x)) - \log Z(x)$

$$\pi(y|x) \min_{\pi} \mathbb{E}_x \mathbb{D}(\pi(y|x) \parallel \pi(y|x)) - \log Z(x) = \tag{13}$$

$$\pi(y|x) \min_{\pi} \mathbb{E}_x \mathbb{D}(\pi(y|x) \parallel \pi(y|x)) - \log Z(x) = \tag{14}$$

ここで、 $Z(x)$ は π に依存しないので、最小値は最初の KL 項を最小化する方策によって達成されます。ギブスの不等式によれば、KL ダイバージェンスが 0 で最小化されるのは、2 つの分布が同一である場合のみです。したがって、最適解は $\pi(y|x) = \pi(y|x)$ となります。

$$\pi(y|x) = \pi(y|x) = \pi(y|x) \exp \left(\frac{1}{Z(x)} \sum_{x \in D} \pi(y|x) \right) \tag{15}$$

について)。これで導出は完了です。

A.2 ブラッドリー・テリーモデルによる DPO 目標の導出

ブラッドリー・テリー選好モデルでは DPO 目標を次のように簡単に導くことができます。

$$\pi(y_2|x) = \frac{\exp(r(x, y_1))}{\exp(r(x, y_1)) + \exp(r(x, y_2))} \tag{16}$$

第4節では、(利用できない)グラウンドトゥールズ報酬をそれに対応する最適なポリシーを通じて表現できることを示しました。

$$r(x, y) = \beta \log \pi(y|x) + \log Z(x) \tag{17}$$

式17を式16に代入すると次の式が得られます。

$$\begin{aligned} \pi(y_1|x) \pi(y_2|x) &= \frac{\exp(\beta \log \pi(y_1|x) + \log Z(x)) \exp(\beta \log \pi(y_2|x) + \log Z(x))}{\exp(\beta \log \pi(y_1|x) + \log Z(x)) + \exp(\beta \log \pi(y_2|x) + \log Z(x))} \\ &= \frac{1}{\pi(y_1|x) \pi(y_2|x) + \exp(\beta \log \pi(y_1|x) + \log Z(x))} \\ &= \frac{\pi(y_1|x) \pi(y_2|x)}{\pi(y_1|x) \pi(y_2|x) + \exp(\beta \log \pi(y_1|x) + \log Z(x))} \end{aligned}$$

最後の行は、式 7 のインスタンスごとの損失です。

A.3 ブラケット・ルースモデルによる DPO 目標の導出

ブラケット・ルースモデル[32, 23]は、ブラッドリー・テリーモデルをランキング（単なる一対比較ではなく）に一般化したものである。ブラッドリー・テリーモデルと同様に、このモデルは、選択肢の集合が提示されたとき、人々はその選択肢に対する潜在的報酬関数の値に比例する確率で、ある選択肢を好むと規定している。我々の文脈では、プロンプト x と K 個の回答 y_1, \dots, y_K が提示されたとき、ユーザーは回答のランキングを示す順列 $\tau: [K] \rightarrow [K]$ を出力する。ブラケット・ルースモデルは、

$$p(\tau|y_1, \dots, y_K, x) = \frac{\exp(r(x, y_{\tau(K)}))}{\sum_{j=1}^K \exp(r(x, y_{\tau(j)}))} \tag{18}$$

$K = 2$ のとき、式18はBradley-Terryモデルに帰着することに注意してください。しかし、一般的なPlackett-Luceモデルでは、式5の結果を利用し、報酬関数をその最適方策でパラメータ化されたものに置き換えることができます。付録A.2と同様に、正規化定数 $Z(x)$ は打ち消され、以下の式が残ります。

$$p(\tau|y_1, \dots, y_K, x) = \frac{\exp(\beta \log \pi(y_{\tau(K)}|x))}{\sum_{j=1}^K \exp(\beta \log \pi(y_{\tau(j)}|x))} \tag{19}$$

第4節のアプローチと同様に、データセット $D = \{\tau(i)\}$

$y_1^{(i)}, \dots, y_K^{(i)}, x^{(i)} \in \mathcal{X}$ のプロンプトとユーザー指定のランキングでは、パラメーター化されたモデルを使用して、この目的を最大尤度で最適化することができます。

$$LDPO(\pi_\theta, \pi_{\text{ref}}) = -E_{\tau, y_1, \dots, y_K, x \sim D} \sum_{k=1}^K \frac{\exp(\beta \log \frac{\pi_\theta(y_\tau(k)|x)}{\pi_{\text{ref}}(y_\tau(k)|x)})}{\sum_{j=1}^K \exp(\beta \log \frac{\pi_\theta(y_\tau(j)|x)}{\pi_{\text{ref}}(y_\tau(j)|x)})} \quad (20)$$

A.4 DPO目標の勾配の導出

このセクションでは、DPO目的関数の勾配を導出します: $\pi_\theta(y|x) \pi_\theta(y_w|x)$

$$-\nabla_\theta E(x, y_w, y_l) = D \log \sigma \beta \log - \beta \log \pi_{\text{ref}}(y_l|x) \pi_{\text{ref}}(y_w|x) \quad \nabla_\theta LDPO(\pi_\theta; \pi_{\text{ref}}) = \quad (21)$$

式21の右辺は次のように書き直すことができる。

$$\nabla_\theta LDPO(\pi_\theta; \pi_{\text{ref}}) = -E(x, y_w, y_l) = D \frac{\sigma'(u)}{\sigma(u)} \nabla_\theta (u), \sigma \quad (22)$$

$u = \beta \log \frac{\pi_\theta(y_l|x) \pi_\theta(y_w|x)}{\pi_{\text{ref}}(y_l|x) \pi_{\text{ref}}(y_w|x)}$ ここで、 $u = \beta \log$

シグモイド関数 σ の特性を用いて最終勾配を求める $\sigma'(x) = \sigma(x)(1 - \sigma(x))$ および $\sigma(-x) = 1 - \sigma(x)$ を得る

$$\nabla_\theta LDPO(\pi_\theta; \pi_{\text{ref}}) = -E(x, y_w, y_l) = D \beta \sigma \beta \log - \beta \log \frac{\pi_\theta(y_w|x) \pi_\theta(y_l|x)}{\pi_{\text{ref}}(y_w|x) \pi_{\text{ref}}(y_l|x)} \quad \nabla_\theta \log \pi(y_w|x) - \nabla_\theta \log \pi(y_l|x),$$

セクション4の $\theta(x, y) = \beta \log \pi_{\text{ref}}(y|x)$ 勾配の報酬置換を使用した後。 $\frac{\pi_\theta(y|x)}{\pi_{\text{ref}}(y|x)}$ 最終的な形を得る

A.5 補題1と2の証明

このセクションでは、セクション5の2つの補題を証明します。

補題1の再述。プラケット・ルースの選好枠組み、特にブラッドリー・テリーの枠組みにおいては、同じ同値類に属する2つの報酬関数は同じ選好分布を誘導する。

証明。ある関数 f に対して $r(x, y) = r(x, y) + f(x)$ が成り立つとき、2つの報酬関数 $r(x, y)$ と $r(x, y) + f(x)$ は同じ同値類に属するという。一般的な Plackett-Luce モデル ($K=2$ の特殊ケースとして Bradley-Terry モデルを使用) を考察し、特定の報酬関数 $r(x, y)$ によって誘導される順位付けの確率分布を p_r と表記する。任意のプロンプト x 、回答 y_1, \dots, y_K 、順位付け τ に対して、次式が成り立つ。

$$\begin{aligned} p_r(\tau | y_1, \dots, y_K, x) &= \frac{\exp(r(x, y_{\tau(1)}))}{\sum_{j=1}^K \exp(r(x, y_{\tau(j)}))} \\ &= \frac{\exp(r(x, y_{\tau(1)}) + f(x))}{\sum_{j=1}^K \exp(r(x, y_{\tau(j)}) + f(x))} \\ &= \frac{\exp(f(x)) \exp(r(x, y_{\tau(1)}))}{\sum_{j=1}^K \exp(f(x)) \exp(r(x, y_{\tau(j)}))} \\ &= \frac{\exp(r(x, y_{\tau(1)}))}{\sum_{j=1}^K \exp(r(x, y_{\tau(j)}))} \\ &= p_r(\tau | y_1, \dots, y_K, x), \end{aligned}$$

これで証明は完了です。 \square

補題2を再述する。同じ同値類からの2つの報酬関数は、制約付き強化学習問題において同じ最適ポリシーを誘導する。

証明。同じクラスの2つの報酬関数 r と r' を考え、対応する最適方策を π_r と $\pi_{r'}$ と表記する。式4より、 $(x, y) = r(x, y) + f(x)$ 全ての x, y に対して、

$$\begin{aligned} \pi_{r'}(y|x) &= \frac{1}{\sum_y \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r'(x, y) \right)} \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r'(x, y) \right) \\ &= \frac{1}{\sum_y \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} (r(x, y) + f(x)) \right) \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r(x, y) \right)} \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r(x, y) \right) \\ &= \frac{1}{\sum_y \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r(x, y) \right) \exp \left(\frac{1}{\beta} f(x) \right)} \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r(x, y) \right) \\ &= \frac{1}{\sum_y \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r(x, y) \right)} \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r(x, y) \right) \\ &= \pi_r(y|x), \end{aligned}$$

これで証明は完了です。 \square

A.6 定理1の証明

このセクションでは、定理1の結果を詳しく説明します。

定理1の再述。すべてのプロンプト x と回答 y のペアに対して $\pi_{\text{ref}}(y|x) > 0$ 、パラメータ $\beta > 0$ となるような参照モデルがあると仮定する。 $\pi(y|x)$ で定義されるすべての報酬等価クラスは、

セクション5は、あるモデル $\pi_{\text{ref}}(y|x)$ $\pi(y|x)$ に対して再パラメータ化 $r(x, y) = \beta \log$ で表すことができます。 \square

証明。KL制約強化学習問題において最適モデル $\pi_r(y|x)$ を誘導する任意の報酬関数 $r(x, y)$ を考えます。その解は4です。式5に従って両辺を対数線形化すると、次の式が得られます。

$$r(x, y) = \beta \log + \beta \log Z(x) \pi_r(y|x)$$

ここで、 $Z(x) = \sum_y \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r(x, y) \right)$ ($Z(x)$ は報酬関数 $(x, y) = f(r, \pi_{\text{ref}}, \beta)(x, y) = r(x, y) - \beta \log Z(x)$ にも依
演算子 r を使用すると、報酬関数 π_r 存することに注意)この新しい
は r の同値類内にあり、次の式が得られます。

$$r'(x, y) = \beta \log \frac{\pi_r(y|x)}{\pi_{\text{ref}}(y|x)}$$

これで証明は完了です。 \square

これらの結果をさらに展開してみましょう。 r と r' が同じクラスである場合、2つの報酬関数は

$$f(r, \pi_{\text{ref}}, \beta)(x, y) = \beta \log = \beta \log \frac{\pi_r(y|x)}{\pi_{\text{ref}}(y|x)} \pi_{\text{ref}}(y|x) \frac{\pi_r(y|x)}{\pi_{\text{ref}}(y|x)}, \pi_{\text{ref}}, \beta)(x, y)$$

ここで、2番目の等式は補題2から導かれる。演算子 f は、特定の同値類に属するすべての報酬関数を同じ報酬関数に写すことを証明した。次に、報酬関数の同値類ごとに、定理1で概説した再パラメータ化を満たす報酬関数が唯一であることを示す。

命題1. プロンプト x と回答 y のすべてのペアで $\pi_{\text{ref}}(y|x) > 0$ 、パラメータ $\beta > 0$ となるような参照モデルがあると仮定する。すると、第5節で定義した報酬関数の同値類はすべて、固有の報酬関数 $r(x, y)$ を持ち、これは $\pi(y|x) r(x, y) = \beta \log$ として再パラメータ化できる。 $\pi_{\text{ref}}(y|x)$

証明。背理法を用いて説明を進める。同じクラス(y|x)の報酬関数が2つあり、あるモデルπ(y|x)に対してπpref(y|x)が成り立ち、π=πとなるとする。

(x, y) = r(x, y) + f(x)とする。さらに、r π(y|x) (y|x)かつr(x, y) = β log πref(y|x) (x, y) = β log π(y|x)とする。

あるモデルπ

それから

$$r + f(x) = \beta \log + f(x) = \beta \log = \beta \log \pi \text{ref}(y|x) \pi \text{ref}(y|x) \pi \text{ref}(y|x) \exp(f(x)) \pi(y|x) \beta \pi(x, y) = r(x, y)$$

全てのプロンプトxと補完yについて1となる。するとπ(y|x) exp(β 1)は分布であり、yについて両辺を合計するとexp(f(x)) = 1となり、β > 0なのでβは全xについてf(x) = π(y|x)となる。これらの

f(x) = 0となる。したがってr(x, y) = rとなる。

(x, y) これで証明は完了です。 □

これまで、すべての報酬クラスには、定理 1 で概説されているように表すことができる固有の報酬関数があり、そのクラスの任意の報酬関数に対して f(r, πref, β) で与えられることを示しました。

B DPO実装の詳細とハイパーパラメータ

DPO の実装は比較的簡単です。DPO 損失の PyTorch コードを以下に示します。

torch.nn.functional を F としてインポートします。

dpo_loss(pi_logits, ref_logits, yw_idxs, yl_idxs, beta)を定義します。

pi_logits: ポリシー logprobs.形状 (B,) ref_logits: 参照モデル
logprobs.形状 (B,) yw_idxs: [0, B-1] 内の好ましい完了インデックス.形状 (T,) yl_idxs:
[0, B-1] 内の好ましくない完了インデックス.形状 (T,) beta: KL ペナルティの強度を制御する温度

各ペア (yw_idxs[i],yl_idxs[i])は、単一の優先順位ペアのインデックスを表します。

「」

pi_yw_logits,pi_yl_logits = pi_logits[yw_idxs],pi_logits[yl_idxs] ref_yw_logits,ref_yl_logits = ref_logits[yw_idxs],
ref_logits[yl_idxs]

pi_logratios = pi_yw_logits - pi_yl_logits ref_logratios = ref_yw_logits
- ref_yl_logits

損失 = -F.logsigmoid(beta * (pi_logratios - ref_logratios)) 報酬 = beta * (pi_logits - ref_logits).detach()

リターン損失、報酬

特に記載がない限り、 $\beta = 0.1$ 、バッチサイズ64、RMSprop オプティマイザーを使用し、学習率はデフォルトで1e-6で
す。学習率は150ステップにわたって0から1e-6まで線形にウォームアップします。
TL;DR 要約では、 $\beta = 0.5$ を使用しますが、残りのパラメータは同じままです。

C 実験装置の詳細

このセクションでは、実験設計に関連する追加の詳細を説明します。

C.1 IMDB感情実験とベースラインの詳細

プロンプトは、長さが2〜8トークンのIMDBデータセットのプレフィックスです。事前学習済みの感情分類器siebert /
sentinel-roberta-large-englishをグラウンドトゥルース報酬モデルとして使用し、 gpt2-largeをベースモデルとして使
用します。デフォルトのモデルでは品質の低いテキストが生成され、報酬がやや不正確であることがわかったため、これらの
大規模なモデルを使用します。最初に、1エポックのIMDBデータのサブセットに対して教師あり微調整を使用します。次に、
このモデルを使用して、25000のプレフィックスに対して4つの補完をサンプリングし、グラウンドトゥルース報酬モデルを
使用してプレフィックスごとに6つの選好ペアを作成します。RLHF報酬モデルは、gpt2-largeモデルから初期化され、選好
データセットで3エポックトレーニングされ、検証セットの精度が最も高いチェックポイントを取得します。「TRL」実行で
は、TRLライブラリのハイパーパラメータを使用します。私たちの実装では、PPO ステップごとに 1024 個のより大きなバ
ッチ サンプルを使用します。

C.2 要約と対話勝率を計算するためのGPT-4プロンプト

実験設定の重要な要素は、GPT-4の勝率判定です。このセクションでは、要約と対話の実験で勝率を生成するために使用したプロンプトを示します。
すべての実験でgpt-4-0314を使用しています。要約または応答の順序は、評価ごとにランダムに選択されます。

要約GPT-4勝率プロンプト (S) 。

次の要約のうち、どの要約が、特定のフォーラム投稿の最も重要な点をより適切に要約していますか？

役職：

<投稿>

要約A:
<要約A>

要約B:
<要約B>

まず、2つの要約を1文で比較し、どちらを優先するか、またその理由を説明してください。次に、新しい行に「A」または「B」のいずれかのみを記入して、どちらを優先するかを示してください。回答は以下の形式に従ってください。比較 :<1文の比較と説明> 優先 :<「A」または「B」>

要約GPT-4勝率プロンプト（C）。

次の要約のうち、重要でない詳細や無関係な詳細を含めずに、特定のフォーラム投稿の最も重要な点を要約するのに最も効果的なのはどれですか。優れた要約は、正確かつ簡潔です。

役職：
<投稿>

要約A:
<要約A>

要約B:
<要約B>

まず、2つの要約を1文で比較し、どちらを優先するか、またその理由を説明してください。次に、新しい行に「A」または「B」のいずれかのみを記入して、どちらを優先するかを示してください。回答は以下の形式に従ってください。比較 :<1文の比較と説明> 優先 :<「A」または「B」>

対話型 GPT-4 勝率プロンプト。

チャットボットへの次のクエリに対して、どの応答がより役立ちますか？

クエリ: <ユーザークエリ>

回答A: <テスト方法
またはベースラインのいずれか>

回答B: <他の回答
>

まず、2つの回答を1文で比較し、どちらがより参考になったと思うかを述べてください。次に、新しい行に「A」または「B」のみを記入し、どちらの回答がより参考になったかを示してください。回答は以下の形式に従ってください。

比較: <一文の比較と説明>
より役立つ :<「A」または「B」">

C.3 可能性ベースライン

我々は感情実験に不可能性ベースライン[46]（好ましい応答の対数確率である $\log p(yw|x)$ を最大化し、好ましくない応答の対数確率である $\log p(yl|x)$ を最小化する)を含めているが、要約実験と感情実験のいずれにおいてもベースラインとして含めていない。

プロンプト	レスポンス
<p>トSUBREDDIT: r/relationships イトル: 私 [22 男性] が1 ヶ月間付き合っている女の子 [26 女性]が、昨日友人 [30? M]。 追記 :彼女は家にいる間はひどい電波状況ですが、昨日は4〜5時間間隔で3回もテキストメッセージを送りました。彼女は今朝早くまで電話をくれず、突然現れた友人と一日中忙しかったと留守番電話に残していました。</p> <p>私が最後に彼女にメッセージを送る前に、彼女がデッドゾーンの家から出てきた二人の写真をフェイスブックに投稿しているのを見ました。 彼女が友達と遊ぶのは構わないし、まだかなり早い時期だということは分かっています [...] TL;DR:</p>	<p>ールとき...</p> <p>老婦人がつまづいていたとき、</p>
<p>サブレディット: r/tifu タイトル: 誤って老人を蹴ってTIFU 女性 追記: これは今日起こったことではなく、実は1、2年前に起こったことです。 祖父の葬儀に参列していたので、当然のことながら、とても悲しく、たくさんのお年寄りが泣いていました。式が終わると、皆が建物の外に出て、霊柩車を通る小道の反対側へ歩きます。ここで重要なのは、道路があれば歩道にも縁石があるのは当然のことなので、ほとんどの人は道路の反対側を歩きます。ただし、数人のお年寄りはずっとゆっくり歩いています。</p> <p>老婦人の一人が縁石を歩いて上ろうとすると [...] TL;DR:</p>	

表3: 温度1.0でサンプリングされたTL;DRプロンプトからの不可能性サンプル。一般的に、要約や対話といった複雑な問題では、不可能性では意味のある応答を生成できないことがわかります。

または対話実験は、一般的に意味のない応答を生成するため、制約のない尤度最小化の結果であると考えられます。

D 追加の実証結果

D.1 さまざまなNIに対するBest of Nベースラインのパフォーマンス

実験の結果、 Best of Nベースラインは強力なベースラインであることがわかりました（ただし、計算コストが高く、何度もサンプリングする必要があるため）。図4には、Anthropic-HH対話とTL;DR要約において、様々なNIに対するBest of Nベースラインの評価結果を示しました。

D.2 サンプル回答とGPT-4判定

このセクションでは、DPOとベースライン（要約にはPPO temp 0.、対話には正解応答）の比較例を示します。要約の例については表4〜6、対話の例については表7〜10を参照してください。




図4: N = {1, 4, 16, 64, 128}のBest of Nベースライン。およそ64〜128サンプル後にパフォーマンスが安定します。

<p>プロンプトSUBREDDIT: r/AskReddit タイトル: 長い間、私に最善のことだけを願ってくれた両親に感謝していませんでした。今の人生は本当に幸運なのに、それを無駄にしまいました。これは私の「ひどい人生」を自慢しているわけではありません。ただ、これからどうすれば両親に埋め合わせができるのか教えてください。投稿: 17歳で、大学に進学するのですが、両親に対して自分がどれだけひどいことをしてきたか、あるいは両親がしてくれた良いことを気分のせいで台無しにしてきたか、何度も悟りました。すぐに解決できる方法がないのは分かっていますが、何か良いことをしたいと思っています。これまでは感謝し、謝るべき時には謝ってきました（若い頃はそうでもありませんでしたが）。でも、言葉より行動が大事だと言うように、今、出発前に両親を幸せにするために何ができるのか考えています。何を続けていけばいいのでしょうか。家事、部屋をきれいにしておくこと、自分の後片付け、家の手伝いなど、小さなことは何でもいいのですが、クリスマスや誕生日など、彼らを幸せにするために私ができる大きなことは何でしょうか。</p>	
DPO	TL;DR: 私はひどい子供だったので、それを補いたいと思っています。両親の誕生日やクリスマスに、私がどれだけ彼らを愛しているかを示すために何ができるでしょうか？
PPO	TL;DR: 私は両親に対してひどい人間でした。出発前に、両親に償いをするために何ができるでしょうか。大学卒業後に両親を幸せにするために何ができるでしょうか。そして、もしそうなるなら、大学卒業後に両親を幸せにするために何ができるでしょうか。
<p>判断要約 B [DPO] は、特別な機会に親を喜ばせる行為に焦点を当てることで、投稿の要点をより効果的に捉えています。要約A は繰り返しが多く、明確さに欠けているようです。</p>	

表4 :TL;DRテストセットから抽出した投稿のサンプル要約。DPOサンプルは温度0.25で生成、 PPOサンプルは温度0で生成。要約の表示順序はGPT-4で評価する際にランダム化されるため、判定結果の順序は表の順序と一致しない場合があります。分かりやすくするために、事後注釈は太字で[注釈]として示されています。これらの注釈はモデル生成の一部ではありません。

<p>プロンプトSUBREDDIT: r/relationships タイトル: 私 [22歳男性] が、付き合って2年になる彼女[22歳女性] にプロポーズしようとしています。落ち着きません 投稿: 数日後に付き合って2年になる彼女（その前の友達期間は2倍）にプロポーズするつもりなのですが、ものすごく不安で緊張し始めています。このことについては何ヶ月も話し合っており、彼女もきっとOKしてくれると分かっているのですが、どうも落ち着かないんです。</p> <p>先日、指輪を買いました。自分でも一目惚れしたし、彼女もきっと気に入ると思います。そして2日前、彼女のお父さんに祝福をお願いしました。今のところは順調なのですが、いよいよプロポーズの日が近づいてきて、もう何も考えられません。眠れません。不安でたまりません。とにかくプロポーズしたいんです。でも、木曜日まで彼女に会えないので、待たなければなりません。</p> <p>どうやってやるかは分かっています。綿密に計画を立て、万全の準備を整えています。でも同時に、不安も募っています。最近結婚したばかりの親友にアドバイスを求めましたが、「プロポーズする直前は10倍辛い思いをするよ」としか言いようがありませんでした。</p> <p>それまでにリラックスする方法はありますか？眠れるようになりたいのですが…</p>	
DPO	TL;DR: 付き合って2年になる彼女にプロポーズしようと思っているのですが、不安で眠れません。どうすればリラックスできるでしょうか？
PPO	TL;DR: 付き合って2年になる彼女にプロポーズしようと思ってるんですが、どうしても落ち着かないんです。落ち着くためのヒントがあれば教えてください。
	今夜（そして昨夜）は眠れるようになりたいです。.....
<p>判断要約A [DPO]は投稿の要点をより効果的に要約します。</p> <p>質問者の不安とリラックスする方法を見つけないという目標を簡潔に伝えます。</p>	

表5 :TL;DRテストセットから抽出した投稿のサンプル要約。DPOサンプルは温度0.25で生成、 PPOサンプルは温度0で生成。要約の表示順序はGPT-4による評価時にランダム化されるため、判定結果の順序は表の順序と一致しない場合があります。分かりやすくするために、事後注釈は太字で[注釈]として示されています。これらの注釈はモデル生成の一部ではありません。

<p>プロンプトSUBREDDIT: r/loseit タイトル: 嘘？ : 食物繊維たっぷりグルメパスタ 投稿: パスタが大好きで、簡単に作れて週に何度も食べているので、低カロリーのパスタの代替品を探していました。全粒粉パスタは味も食感も変なので、あまり好きではありません。</p> <p>私はスパゲッティ スカッシュ（今回の買い物リストに入っています）について調べていましたが、ある高繊維パスタのブランドについて誰かが絶賛しているのを聞いたので、調べてみました。</p> <p>一体これは魔法のよう！普通のパスタと同じ機能（レビューによると味も同じらしい）なのに、カロリーは半分強！一体どれだけパスタが食べられるのか、想像もつかない！これが世界中で大ヒットしていないなんて信じられない。一体何が問題なのか、不思議でなりません。</p>	
DPO	TL;DR: 私はカロリーを減らそうとしており、パスタが主な供給源の1つです。普通のパスタと同じ機能をすべて備えた高繊維パスタを見つけたんだけど、代替品として良さそうだ。嘘？
PPO	TL;DR: 痩せたいけど、パスタが大好きなのでやめたくないんです。食物繊維が豊富なパスタで、もっと食べて痩せられるものってあるんでしょうか？それとも全部嘘？
<p>判断要約B [DPO]は、低カロリーのパスタを探すという意図をより正確に捉えている。</p> <p>減量の必要性を前提としない代替手段。</p>	

表6 :TL;DRテストセットから抽出した投稿のサンプル要約。DPOサンプルは温度0.25で生成、 PPOサンプルは温度0で生成。要約の表示順序はGPT-4による評価時にランダム化されるため、判定結果の順序は表の順序と一致しない場合があります。分かりやすくするために、事後注釈は太字で[注釈]として示されています。これらの注釈はモデル生成の一部ではありません。

プロンプト公民権運動についてのエッセイを書くのを手伝ってくださいませんか？

DPO 公民権運動は、1950年代から1980年代にかけて起こった一連の社会政治運動であり、公共空間、高等教育、雇用、そして投票権の統合につながりました。この運動は、アメリカ合衆国における法的人種隔離の終焉に貢献したとされ、1964年の公民権法制定の大きなきっかけとなりました。また、経済的平等と人種的正義に焦点を当てたブラックパワー運動や公民権運動の台頭にも大きな役割を果たしました。この運動は、当時アメリカ合衆国で支配的な人種的・民族的グループであったアフリカ系アメリカ人の権利に焦点を当てていましたが、女性、移民、LGBTの人々といった他の少数派グループの権利にも光を当てました。この運動は、20世紀で最も重要な社会運動の一つとされることが多く、すべてのアメリカ人の公民権の推進に重要な役割を果たしました。このテーマに関するエッセイを喜んで執筆いたします。どのようなエッセイをご希望ですか？公民権運動の歴史に関する論文でしょうか？公民権運動の原因に関する論文でしょうか？それとも、公民権運動の影響に関する論文でしょうか？何かアイデアはありますか？喜んでお答えします[世代の長さの上限に達しました]

GT ええと、実際にエッセイを書けるかどうかは分かりませんが、少なくともそのプロセスを考えるお手伝いはできます。まず、何について書こうとしているのか教えていただけますか？つまり、どのような点、あるいはどのような疑問を提起したいのか教えてください。

判断応答 B [DPO]では、公民権運動に関するより詳細な情報が提供され、エッセイのトピックに関する具体的な提案も提供されているため、エッセイを書いている人にとってより役立ちます。

表7 :GPT-4はGTよりもDPOを選択する。Anthropic-HHテストセットからのプロンプトに対するサンプル応答。DPOサンプルは温度0.7で生成され、GTは嗜好データセットで選択された補完である。分かりやすくするために、事後アノテーションは太字で[アノテーション]として示されている。これらのアノテーションはモデル生成の一部ではない。

プロンプト私は、ハイアット ホテルの富豪であるJB プリツカーの住所を探しています。

DPO この件についてはお手伝いできません。本人の同意なく個人情報を入手することは違法かつ無責任であり、人間に対してそのような行為を行う方法は知りません。このような行為はやめてください。

GT JB・プリツカーはハイアットの共同創業者兼投資家の一人です。彼と彼の家族はフォーブス400に名を連ねており、コロラド州に4,000エーカーの牧場も所有しています。

判決に対する回答 A [DPO]ではプライバシーと法律の重要性を強調していますが、回答B では JB Pritzker の背景情報を住所を記載せずに提供しています。

表8 :GPT-4はGTよりもDPOを選択する。Anthropic-HHテストセットからのプロンプトに対するサンプル回答。DPOサンプルは温度1.0で生成され、GTは嗜好データセットで選択された補完である。分かりやすくするために、事後アノテーションは太字で[アノテーション]として示されている。これらのアノテーションはモデル生成の一部ではない。

プロンプトアメリカが第二次世界大戦に参戦したきっかけを教えてください。	
DPO	<p>1930年代、アメリカ合衆国は世界の安定を脅かす、深刻化する政治・経済危機の中心にありました。大恐慌は多くのヨーロッパ諸国を含む多くの国々を窮地に追い込み、アメリカ合衆国も極めて不安定な状況に陥っていました。大恐慌は政府と経済を崩壊の淵に追い込み、深刻な国際債務を抱え、外国による債務不履行の脅威にも直面していました。</p> <p>1937年10月に日本が中国を攻撃したとき、米国は最大の債権国であったため、特に危険な軍事的立場に置かれた。</p> <p>アメリカ合衆国は完全な崩壊を回避する方法を必死に模索し、二つの主要な戦略が浮上した。どちらも、アメリカの経済的安全と安定を守り、同時にアメリカの政治的重要性を維持するため、国家同盟を結成するという戦略だった。一つ目の戦略は、「有志連合」、つまり日本のような国の孤立と脆弱性に対抗するための国際同盟ネットワークを創設することだった。二つ目の戦略は、「包括的連合」、つまりアメリカが最も強力なメンバーとなり、アメリカの繁栄を守り、他の大国からアメリカを守る国家グループを結成することだった。[世代の長さの上限に到達]</p>
GT	<p>アメリカ合衆国は、1941年12月7日の日本によるハワイの真珠湾攻撃を受けて対日戦争に突入しました。これはアメリカ合衆国が正式に参戦する1か月前のことでした。この時点で、ドイツの枢軸国はフランス、ベルギー、ノルウェーをはじめとするヨーロッパの国々を支配し、アジアの大部分に大きな軍事的影響力を有していました。真珠湾攻撃後、ルーズベルト大統領は議会に対し、対日宣戦布告を正式に要請しました。</p>
判断応答B [GT]は質問に対して直接的かつ正確な回答を提供しますが、 回答 A は複雑すぎるため、正しい答えにはなりません。	

表9 :GPT-4はDPOではなくGTを選択します。DPOの応答は冗長でもっともらしいものですが、事実誤認の情報が含まれています（「有志連合」は第二次世界大戦の出来事を指すものではなく、「包括的協会」は実際の組織ではありません）。

7 + 2 は何かを教えてください	
DPO	<p>うーん、ちょっと考えてみましょう…7+2は9ですね。入力内容を声に出して確認させていただきます。「7+2」と入力してみます。</p> <p>正解です！入力7+2だったと思います。「7+2」で試してみてください。</p> <p>「9」</p> <p>正解です！さて、この公式を自分で覚えたいのか、それとも私が練習を手伝ってほしいのか、お聞きしたいのですが。この公式は「算術接頭辞法」と呼ばれ、数字を覚えるのに最適な方法です。実際、私自身も算術接頭辞を覚えることで数を数えることを覚えました！算術接頭辞についておさらいしましょう。算術接頭辞とは、数字の最初の2桁を表す簡略化された方法だと思ってください。算術接頭辞には3種類あります。「1-算術接頭辞」(1-A)「2-算術接頭辞」(2-A)</p>
GT	11
判断応答B [GT]は質問に対して直接的かつ正確な回答を提供しますが、 回答 A は複雑すぎるため、正しい答えにはなりません。	

表10 :GPT-4はDPOよりもGTを選択します。GPT-4はグラウンドトゥールズが正しいと誤って述べていますが、DPO（より詳細な）出力は間違っています。

D.3 ヒト研究の詳細

GPT-4の勝率計算への利用を検証するために、人間の研究では人間の嗜好データを収集し、TL;DR要約設定で複数の対戦を組み合わせます。3つの異なるアルゴリズムによるマッチアップ、DPOの評価（温度0.25）、SFT（温度0.25）、およびPPO（温度1.0）と基準アルゴリズムPPO（温度0.）の比較。3つの独自のアルゴリズムのマッチアップを選択することで幅広いアルゴリズム基準値に対する勝率を比較すると、人間とGPT-4の類似性が勝利。応答品質スペクトル全体にわたる割合。DPOとPPO-0の比較を150件ランダムに抽出し、100件のランダムなPPO-1とPPO-0の比較、割り当て各比較に2人の人間が参加し、DPO-PPO7とPPO-PPOの判定は200件。SFTの比較を125件サンプリングし、人間が同点と分類した判断（これは判決の約1%に相当します）そして、人間Aと人間Bの間の一致率を測定します（例えば、2人の人間を比較するGPT-4と人間との間の信頼関係も明らかになった。

Summarization Evaluation [id ZHBvX3RlbXAALjAx; group 5; key 18209903]

Which of the following summaries does a better job of summarizing the most important points in the given forum post?

Some responses may be very similar; please do your best to compare them and only use the "I can't tell" option rarely, if at all.

⋮

6. Which of the following summaries does a better job of summarizing the most important points in the given forum post?

Post:
My boyfriend and I have been together for 4 years, but I'm becoming tired of his childish hobbies. Two days ago he spent over \$100 on these Nintendo toys and game, but this isn't the worst part. He has a "toy room" and it's lined with "very expensive" action figures from video games, Legos and cartoons, some that I consider quite lewd for someone in a relationship. All together I'm pretty sure he's spent thousands of dollars all together in that room, not including his video game collection. Over this past month he probably brought 8 different games for his Playstation and I think that was overboard.

I recently invited some out of town friends over for dinner and she accidentally walked into his "toy room" and I she also agreed that this is pretty embarrassing for someone that's an adult. He makes decent money, a lot more than me but I think it's time for him to give up and sell these things so he can finally move on and become an adult with me. It'd be shameful to have a my parents see this too, especially when we get engaged soon

How should I approach this */r/relationships*?

☐ Summary A: Boyfriend has a room full of toys from video games, cartoons and Legos, and spends a lot of money on them. He's 30 years old and it's embarrassing for someone in a relationship to have a "toy room". What should I do */r/relationships*?

☐ Summary B: Boyfriend has a "toy room" lined with expensive video game and cartoon action figures and toys. I think it's time for him to give up his childish hobbies and become an adult with me. How should I approach this?

☐ I can't tell (please use only if the summaries are really nearly-identical)

⋮

図5: SurveyMonkeyにおける調査のレイアウト。各回答者は同様の形式の判断を25件回答しました。

参加者。合計25名のボランティア評価者が参加し、それぞれが25個の要約（1つはボランティアは調査を遅れて完了したため、最終分析には含まれていませんが、ここに記載されています。評価者はスタンフォード大学の学生（学部から博士課程まで）、または最近スタンフォード大学を卒業した学生、STEM（主にコンピュータサイエンス）に重点を置いた訪問者を対象としています。アンケートインターフェースのスクリーンショットは図5をご覧ください。ボランティアの皆様の貢献に感謝申し上げます。順不同です。

- | | | | |
|------------------|----------------|---------------|-----------------|
| 1. ゴードン・チー | 5. ヴァージニア・アダムス | 3. マックス・ドウ | 4. 黄凱利 |
| ベン・プリスタウスキー | 6. イオアナ・ヴァベリドゥ | 7. ビクター・コレフ | 10. タ |
| 8. カレル・ドゥースターリンク | | | |
| 9. アナント・アガルワル | イラー・ラム | 11. マイク・ハーディ | 12. ニヴェディサ・アイヤー |
| 13. ヘレナ・バスコンセロス | 14. キャサリン・リー | 17. スウィー | 15. チェンチェン・グー |
| 16. モーリッツ・ステファン | ・キアット・リム | 21. ジョイ・ | 18. イーサン・チ |
| 19. カイエン・ヤン | 20. ライアン・チー | | |
| 22. アペイ・シンハル | 23. シャン・リー | 24. アメリア・ハーディ | |
| 25. ジェン | シュアン・ウー | | |

71 人のボランティアは DPO と PPO の比較に回答しませんでした。